Deep Smoke segmentation

1.训练测试网络代码写完了，在colab上还没调试成功。

2.生成数据集的部分

Fig. 1. Pure smoke images generated by computer graphics.

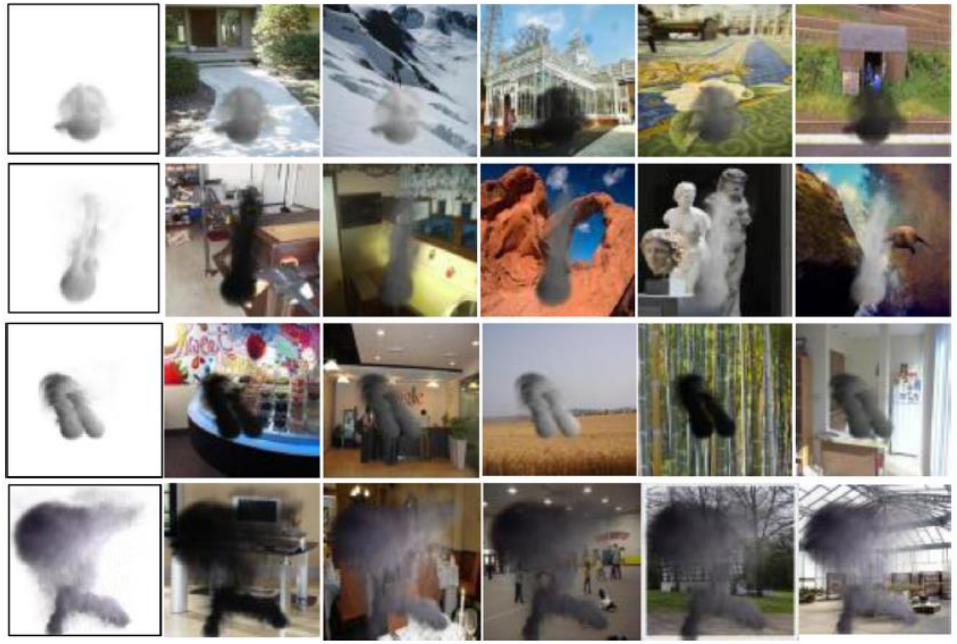

风格迁移

- 可以这样理解VGGNet的结构：前面的卷积层是从图像中提取“特征”，而后面的全连接层把图片的“特征”转换为类别概率。其中，VGGNet中的浅层（如conv1_1，conv1_2），提取的特征往往是比较简单的（如检测点、线、亮度），VGGNet中的深层（如conv5_1、conv5_2），提取的特征往往是比较复杂（如有无人脸或某种特定物体）。
- VGGNet的本意是输入图像，提取特征，并输出图像类别。图像风格迁移正好与其相反，输入特征，输出对应这种特征的图片

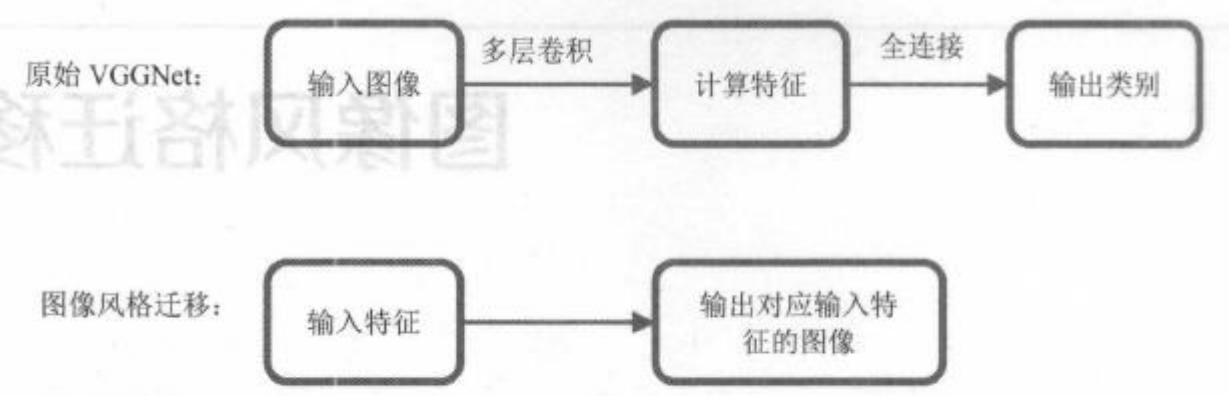

图 7-1　图像风格迁移和对图像提取特征的过程对比

https://blog.csdn.net/czp_374

- 具体来说，风格迁移使用卷积层的中间特征还原出对应这种特征的原始图像。如图7-2a所示，先选取衣服原始图像，经过VGGNet计算后得到各种卷积层特征。接下来，根据这些卷积层的特征，还原出对应这种特征的原始图像。图像b、c 、d 、e 、f 分别为使用卷积层conv1_2、conv2_2 、conv3 _2 、conv4_2 、conv5_2 的还原图像。可以发现：浅层的还原效果往往比较好，卷积特征基本保留了所高原始图像中形状、位置、颜色、纹理等信息；深层对应的还原图像丢失了部分颜色和纹理信息，但大体保留原始图像中物体的形状和位置。

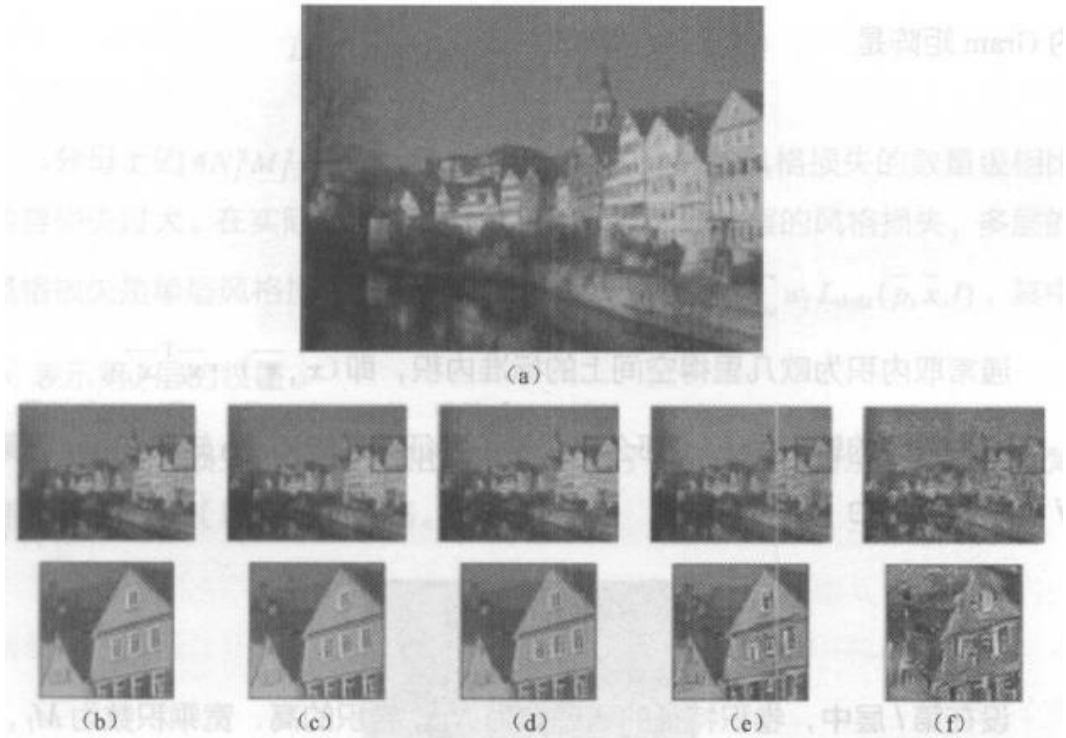

图 7-2　根据 VGGNet 卷积层的特征还原出对应的原始图像（续）

内容损失

还原图像的方法是梯度下降法。设原始图像为$\vec{p}$，期望还原的图像为$\vec{x}$（即自动生成的图像）。使用的卷积是第l层，原始图像$\vec{p}$在第l层的特征为P_{ij}^{l}。i表示卷积的第i个通道，j表示卷积的第j个位置。通常卷积的特征是三维的，三维坐标分别对应（高、宽、通道）。此处不考虑具体的高和宽，只考虑位置j，相当于把卷积“压扁”了。比如一个10x10x32的卷积特征，对应$1 \leqslant i \leqslant 32, 1 \leqslant j \leqslant 100$。对于生成图像$\vec{x}$，同样定义它在$l$层的卷积特征为$F_{ij}^{l}$。

有了上面这些符号后，可以写出“内容损失”（Content Loss）。内容损失$L_{content}(\vec{p}, \vec{x}, l)$的定义是：

$$L_{content}(\vec{p}, \vec{x}, l) = \frac{1}{2} \sum_{i,j} (F_{ij}^{l} - P_{ij}^{l})^2$$

$L_{content}(\vec{p}, \vec{x}, l)$描述了原始图像$\vec{p}$和生成图像$\vec{x}$在内容上的“差异”。内容损失越小，说明他们的内容越接近；内容损失越大，说明他们的内容差距也越大。先使用原始图像$\vec{p}$计算出它的卷积特征P_{ij}^{l}，同时随机初始化$\vec{x}$。接着以内容损失$L_{content}(\vec{p}, \vec{x}, l)$为优化目标，通过梯度下降法逐步改变$\vec{x}$，进过一定的步数后，得到的$\vec{x}$是希望的还原图像了。在这个过程中，内容损失$L_{content}(\vec{p}, \vec{x}, l)$应该是越来越小了。

风格损失-Gram矩阵

知识点！！

Gram矩阵是关于一组向量的内积的对称矩阵，例如，向量组$\vec{x_1}, \vec{x_2}, \ldots, \vec{x_n}$的Gram矩阵是：

$$\begin{bmatrix} (\vec{x_1}, \vec{x_1}) & (\vec{x_1}, \vec{x_2}) & \ldots & (\vec{x_1}, \vec{x_n}) \\ (\vec{x_2}, \vec{x_1}) & (\vec{x_2}, \vec{x_2}) & \ldots & (\vec{x_2}, \vec{x_n}) \\ \ldots & \ldots & \ldots & \ldots \\ (\vec{x_n}, \vec{x_1}) & (\vec{x_n}, \vec{x_2}) & \ldots & (\vec{x_n}, \vec{x_n}) \end{bmatrix}$$

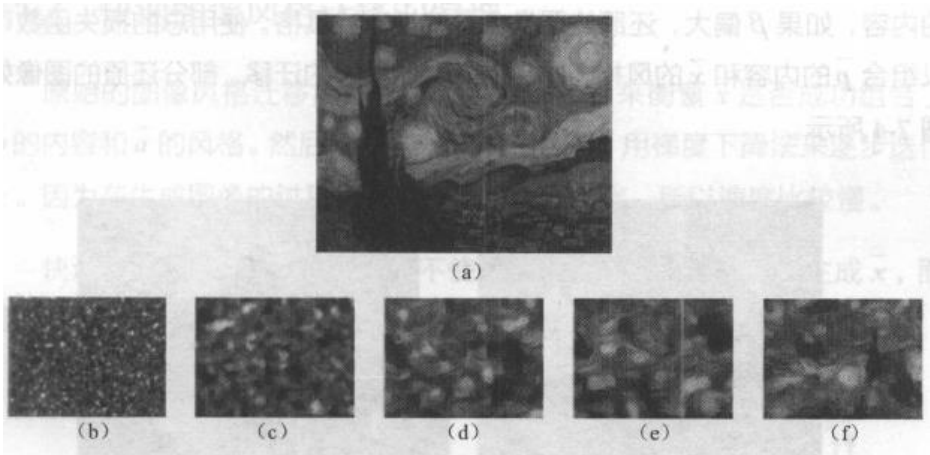

图 7-3 利用“风格损失”还原的图像

https://blog.csdn.net/czp_374

通常取内积为欧几里得空间上的标准内积， 即$(\vec{x_i}, \vec{x_j}) = \vec{x_i}^T \vec{x_j}$。

设卷积层的输出为F_{ij}^l，那么这个卷积特征对应的Gram矩阵的第i行第j个元素定义为
$G_{ij}^l = \sum_k F_{ik}^l F_{jk}^l$

Gram矩阵可以在一定程度上反映原始图像的“风格”。仿照“内容损失”，还可以定义一个“风格损失”（Style Loss）。设原始图像为$\vec{a}$，要还原的风格图像为$\vec{x}$，先计算出原始图像某一层卷积的Gram矩阵为A^l，要还原的图像$\vec{x}$经过同样的计算得到对应卷积层的Gram矩阵是G^l，风格损失定义为

$$L_{style}(\vec{p}, \vec{x}, l) = \frac{1}{4N_l^2 M_l^2} \sum_{i,j} (A_{ij}^l - G_{ij}^l)^2$$

图像风格迁移

设原始的内容图像为$\vec{p}$，原始的风格图像为$\vec{a}$，待生成的图像为$\vec{x}$。希望$\vec{x}$可以保持内容图像$\vec{p}$的内容，同事具备风格图像$\vec{a}$的风格。因此组合$\vec{p}$的内容损失和$\vec{a}$的风格损失，定义总的损失函数为：

$$L_{total}(\vec{p},\vec{a},\vec{x}) = \alpha L_{content}(\vec{p},\vec{x}) + \beta L_{style}(\vec{a},\vec{x})$$

α,β是平衡两个损失的超参数。如果α偏大，还原的图像会更接近$\vec{a}$的风格。使用总的损失函数可以组合$\vec{p}$的内容和$\vec{a}$的风格，这实现了图像风格的迁移。部分还原的图像如图7-4所示。

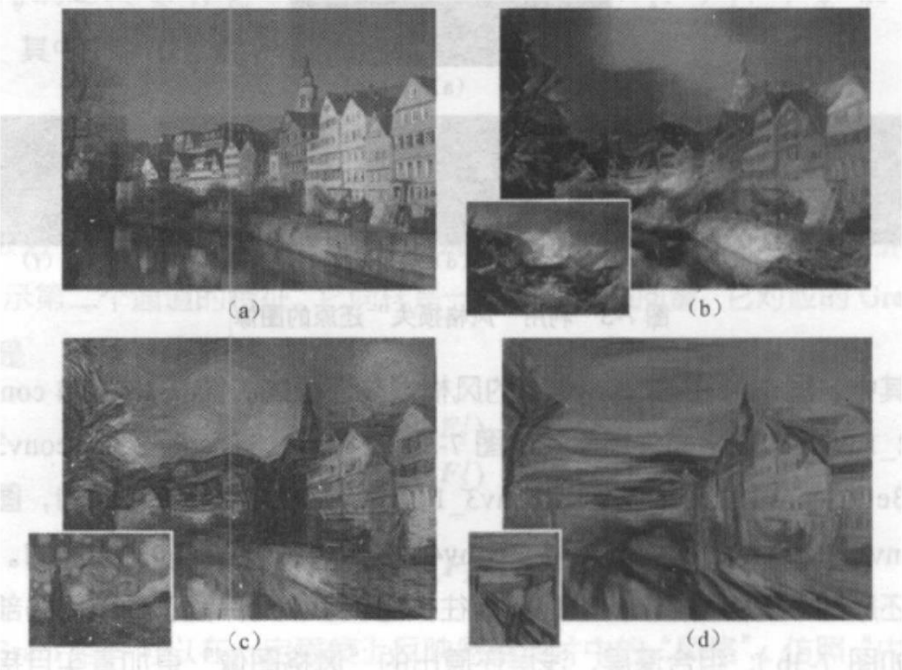

以上是原始的图像风格迁移的基本原理。事实上，原始图像迁移的速度非常慢，在CPU上生成一张图片需要数十分钟甚至几个小时，即使在GPU上也需要数分钟才能生成一张较大的图片，这大大限制了这项技术的使用场景。速度慢的原因在于，要用总损失$L_{total}(\vec{p},\vec{a},\vec{x})$优化图片$\vec{x}$，这意味着生成一张图片需要几百步梯度下降的迭代，而每一步迭代都需要耗费大量的时间。从另一个角度看，优化$\vec{x}$可以看作是一个“训练模型”的过程，以往都是针对模型参数训练，而这里训练的目标是图片$\vec{x}$，而训练模型一般都比执行训练好的模型要慢得多。下一节将会讲到更实用的快速图像风格迁移，它把原来的“训练”的过程变成了一个“执行”的过程，因此大大加快了生成风格化图片的速度。

快速图像风格迁移的原理

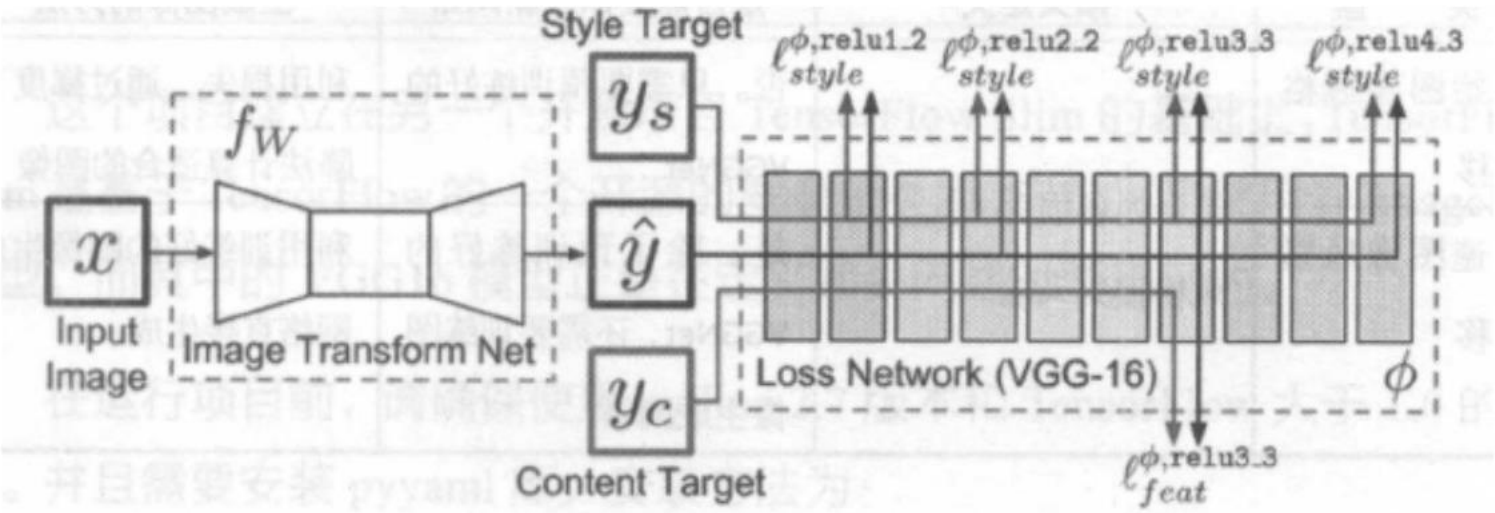

表 7-1 比较了原始图像风格迁移与快速图像风格迁移。

表 7-1　原始图像风格迁移和快速图像风格迁移的比较

类　型	损失定义	是否需要训练新网络	生成图像的方法
原始图像风格迁移	组合内容损失 $L_{content}$ 与风格损失 L_{style}	否。只需要预训练好的 VGGNet	利用损失，通过梯度下降法计算适合的图像
快速图像风格迁移		是。除了预训练好的 VGGNet，还需要训练图像生成网络	利用训练好的图像生成网络直接生成

https://blog.csdn.net/czp_374

Two-Stream Convolutional Networks for Dynamic Texture Synthesis

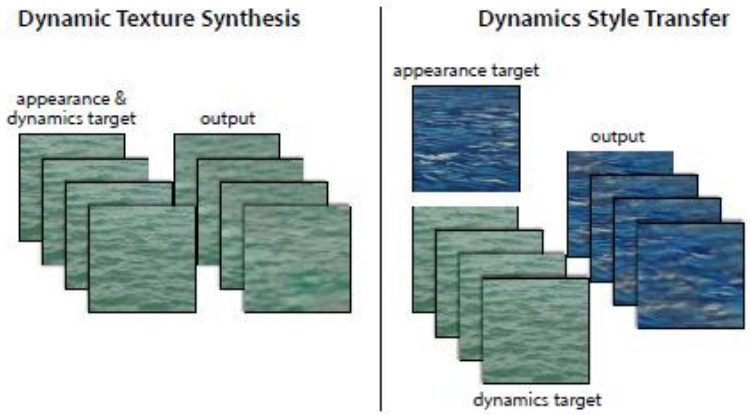

Figure 1: Dynamic texture synthesis. (left) Given an input dynamic texture as the target, our two-stream model is able to synthesize a novel dynamic texture that preserves the target's appearance and dynamics characteristics. (right) Our two-stream approach enables synthesis that combines the texture appearance from one target with the dynamics from another, resulting in a composition of the two.

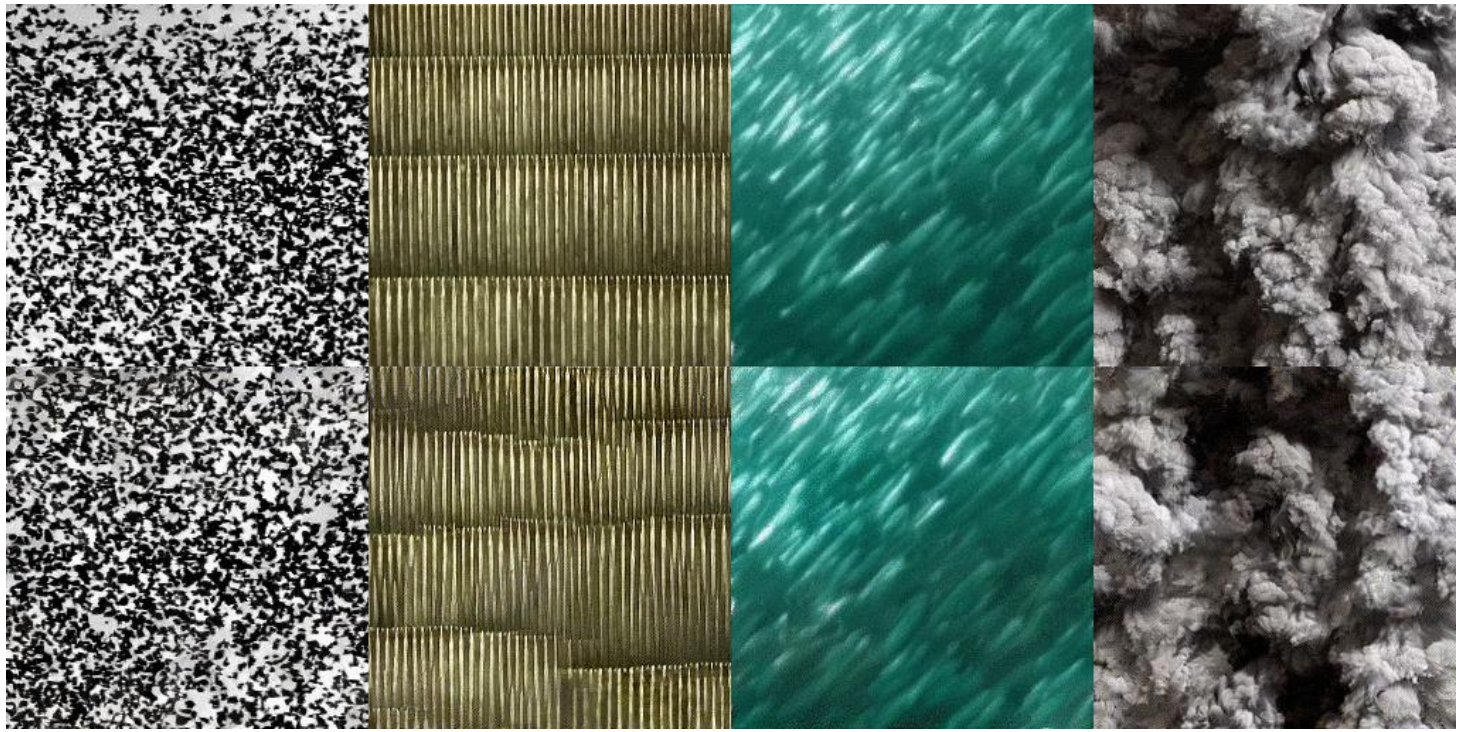

总体流程

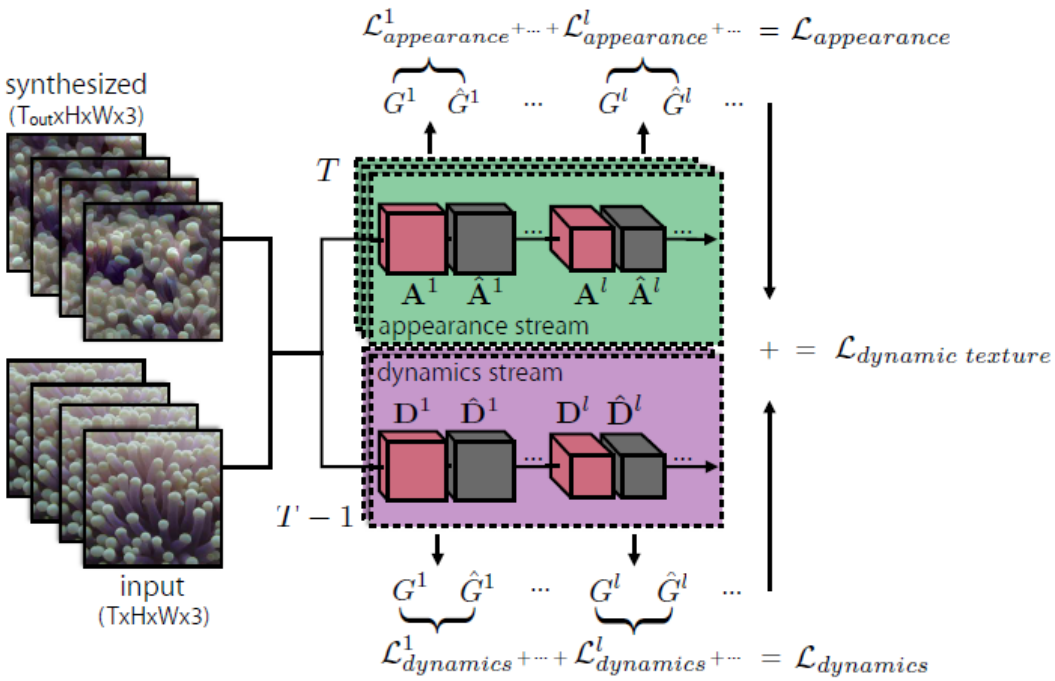

Figure 2: Two-stream dynamic texture generation. Sets of Gram matrices represent a texture's appearance and dynamics. Matching these statistics allows for the generation of novel textures as well as style transfer between textures.

Texture model: Appearance stream

The correlations of the filter responses in a particular layer are averaged over the frames and encapsulated by a Gram matrix, $\mathbf{G}^l \in \mathbb{R}^{N_l \times N_l}$, whose entries are given by $G^l_{ij} = \frac{1}{TN_lM_l}\sum_{t=1}^{T}\sum_{k=1}^{M_l} A^{lt}_{ik}A^{lt}_{jk}$, where T denotes the number of input frames and A^{lt}_{ik} denotes the activation of feature i at location k in layer l on the target frame t. The synthesized texture appearance is similarly represented by a Gram matrix, $\hat{\mathbf{G}}^{lt} \in \mathbb{R}^{N_l \times N_l}$, whose activations are given by $\hat{G}^{lt}_{ij} = \frac{1}{N_lM_l}\sum_{k=1}^{M_l} \hat{A}^{lt}_{ik}\hat{A}^{lt}_{jk}$, where $\hat{A}^{lt}_{ik}$ denotes the activation of feature i at location k in layer l on the synthesized frame t. The appearance loss, $\mathcal{L}_{\text{appearance}}$, is then defined as the temporal average of the mean squared error between the Gram matrix of the input texture and that of the generated texture computed at each frame:

$$\mathcal{L}_{\text{appearance}} = \frac{1}{L_{\text{app}}T_{\text{out}}}\sum_{t=1}^{T_{\text{out}}}\sum_{l}\|\mathbf{G}^l - \hat{\mathbf{G}}^{lt}\|_F^2 , \qquad (1)$$

比较

$$L_{style}(\vec{p}, \vec{x}, l) = \frac{1}{4N_l^2M_l^2}\sum_{i,j}(A^l_{ij} - G^l_{ij})^2$$

Texture model: Dynamics stream

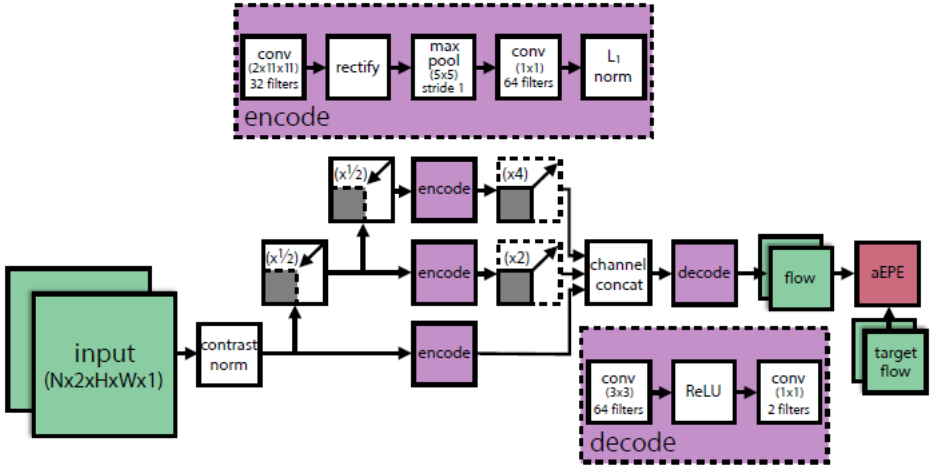

Figure 3: Dynamics stream ConvNet. The ConvNet is based on a spacetime-oriented energy model [7, 39] and is trained for optical flow prediction. Three scales are shown for illustration; in practice five scales were used.

Similar to the appearance stream, filter response correlations in a particular layer of the dynamics stream are averaged over the number of image frame pairs and encapsulated by a Gram matrix, $\mathbf{G}^l \in \mathbb{R}^{N_l \times N_l}$, whose entries are given by $G^l_{ij} = \frac{1}{(T-1)N_l M_l} \sum_{t=1}^{T-1} \sum_{k=1}^{M_l} D^{lt}_{ik} D^{lt}_{jk}$, where D^{lt}_{ik} denotes the activation of feature i at location k in layer l on the target frames t and $t+1$. The dynamics of the synthesized texture is represented by a Gram matrix of filter response correlations computed separately for each pair of frames, $\hat{\mathbf{G}}^{lt} \in \mathbb{R}^{N_l \times N_l}$, with entries $\hat{G}^{lt}_{ij} = \frac{1}{N_l M_l} \sum_{k=1}^{M_l} \hat{D}^{lt}_{ik} \hat{D}^{lt}_{jk}$, where $\hat{D}^{lt}_{ik}$ denotes the activation of feature i at location k in layer l on the synthesized frames t and $t+1$. The dynamics loss, $\mathcal{L}_{\text{dynamics}}$, is defined as the average of the mean squared error between the Gram matrices of the input texture and those of the generated texture:

$$\mathcal{L}_{\text{dynamics}} = \frac{1}{L_{\text{dyn}}(T_{\text{out}}-1)} \sum_{t=1}^{T_{\text{out}}-1} \sum_{l} \|\mathbf{G}^l - \hat{\mathbf{G}}^{lt}\|_F^2, \quad (2)$$

where L_{dyn} is the number of ConvNet layers being used in the dynamics stream.

Texture generation

$$\mathcal{L}_{\text{dynamic texture}} = \alpha \mathcal{L}_{\text{appearance}} + \beta \mathcal{L}_{\text{dynamics}}, \qquad (3)$$

where α and β are the weighting factors for the appearance and dynamics content, respectively. Dynamic textures are implicitly defined as the (local) minima of this loss. Textures are generated by optimizing Eq. (3) with respect to the spacetime volume, *i.e.*, the pixels of the video. Variations in the resulting texture are found by initializing the optimization process using IID Gaussian noise. Consistent with previous work [13], we use L-BFGS [28] optimization.

表 7-1 比较了原始图像风格迁移与快速图像风格迁移。

表 7-1　原始图像风格迁移和快速图像风格迁移的比较

类　型	损失定义	是否需要训练新网络	生成图像的方法
原始图像风格迁移	组合内容损失 $L_{content}$ 与风格损失 L_{style}	否。只需要预训练好的 VGGNet	利用损失，通过梯度下降法计算适合的图像
快速图像风格迁移		是。除了预训练好的 VGGNet，还需要训练图像生成网络	利用训练好的图像生成网络直接生成

https://blog.csdn.net/czp_374

输入

输出