compose=(1-alpha)*background+alpha*beta*smoke

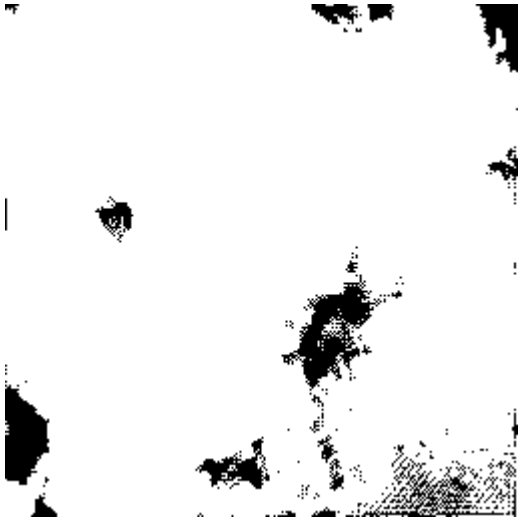

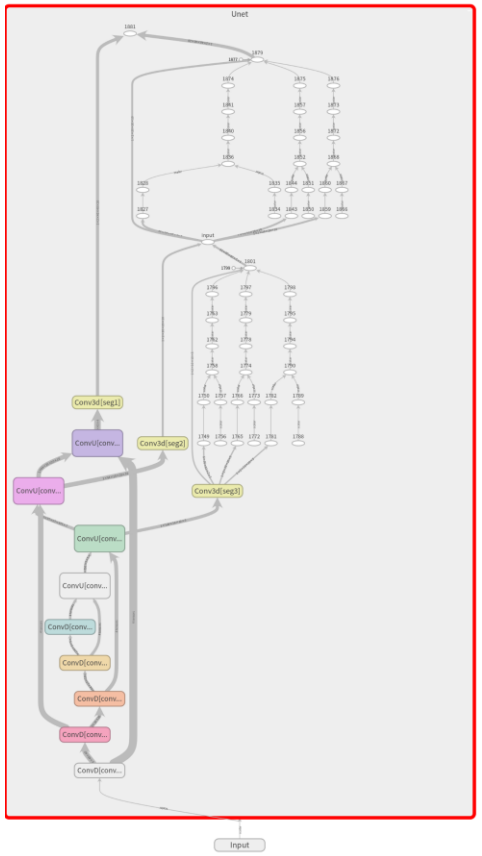

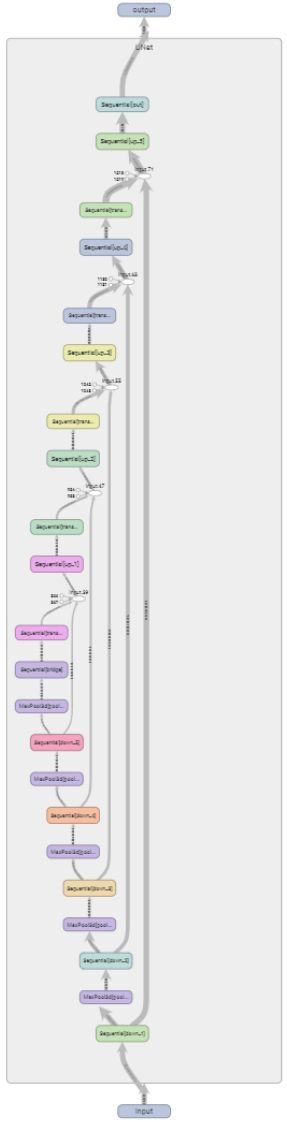

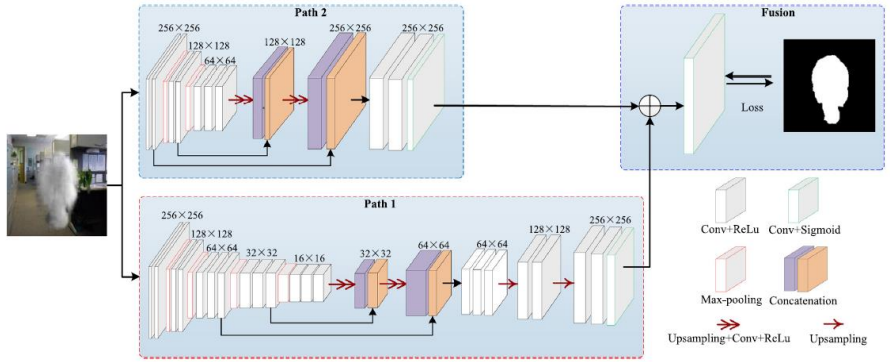

Fig. 3. Our network structure with two paths and skip layers.

利用两路unet的结构，深层获得全局语义信息，浅层获得细节信息

idx	accuary	precision	recall	F1score	iou
17	0.71	0.78	0.86	0.81	0.69
9	0.5	0.56	0.81	0.66	0.5
8	0.78	0.91	0.79	0.85	0.74
29	0.57	0.79	0.59	0.67	0.5

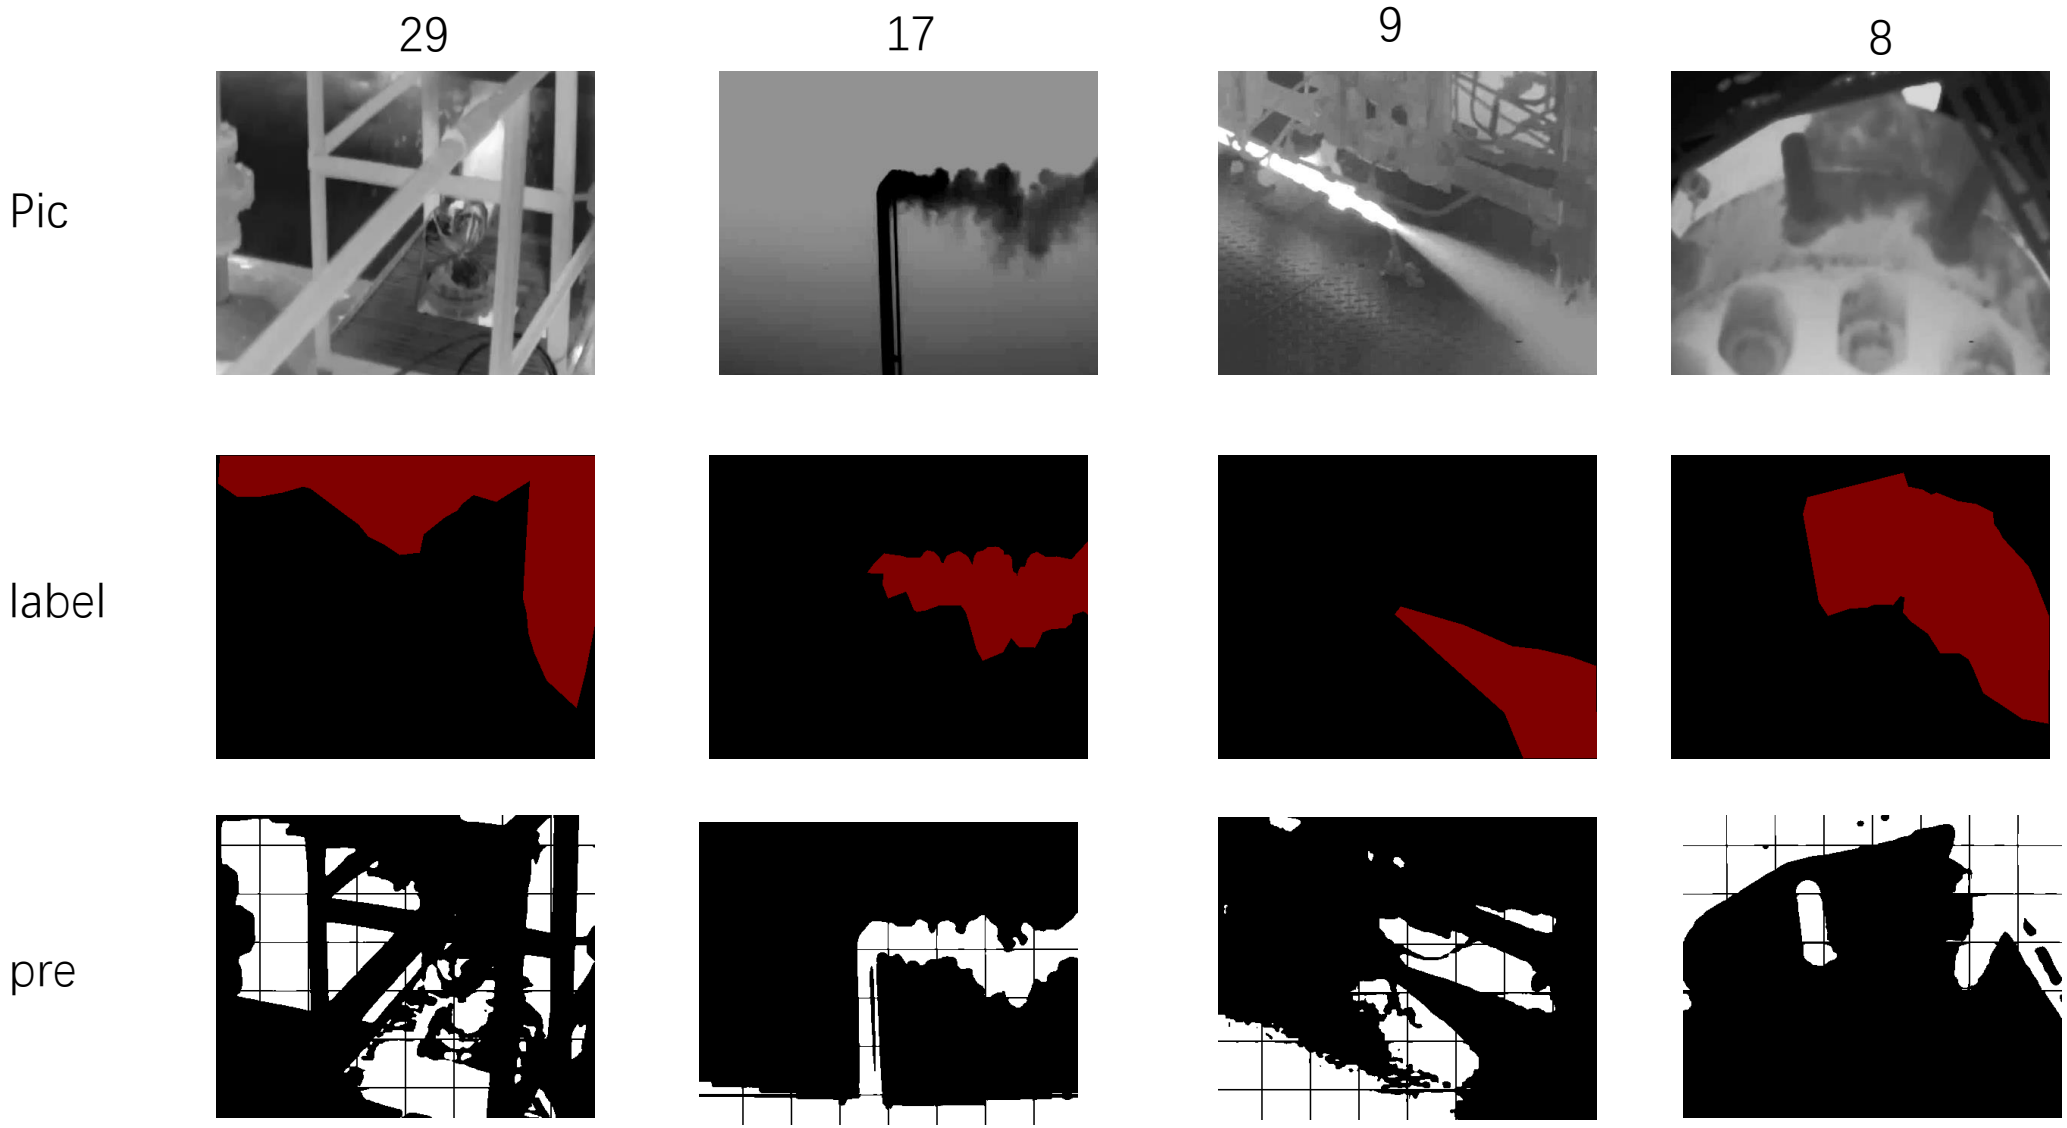

FEELVOS: Fast End-to-End Embedding Learning for Video Object Segmentation

创新点：

- 简单，单网络，single pass
- 迅速，不需要使用第一帧做微调
- 端到端，用于多目标分割，还能支持端到端的训练
- 鲁棒性，在DAVIS2017的验证集上，J&F有65%

亮点：

- 是第一篇解决视频多目标分割同时还是端到端学习的网络。
- 提出一种学习embedding向量的方法，使用global matching和local matching，使得学习embedding向量的方法是端到端的。

网络总体描述

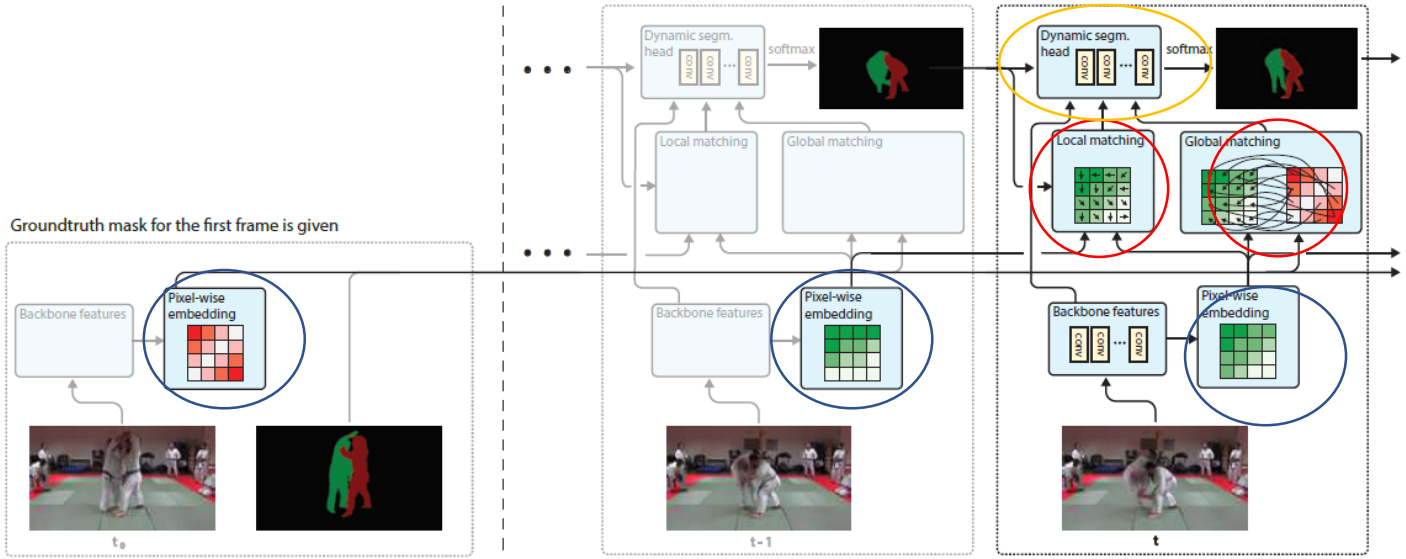

Figure 1. Overview of the proposed FEELVOS method. In order to segment the image of the current frame, backbone features and pixel-wise embedding vectors are extracted for it. Afterwards the embedding vectors are globally matched to the first frame and locally matched to the previous frame to produce a global and a local distance map. These distance maps are combined with the backbone features and the predictions of the previous frame and then fed to a dynamic segmentation head which produces the final segmentation. For details about handling of multiple objects see Fig. 3.

- 先用DeepLabv3+（去除最后的输出层）获得特征信息，在最顶层加上一个embeeding层用来提取embedding 向量。
- 根据embedding向量，通过global matching和 local matching得到两个distance map。
- 将两个distance map，DeepLabv3+提出的特征，前一帧的预测结果一共四个成分当做输入，送入到一个dynamic segmentation head中，这个头网络本质是4个深度分离卷积的stack。然后得到预测结果。
- 以上过程对帧中的每一个实例都进行一次，所以所用时间是随着实例的数目线性增加的。

- 论文的一大亮点是embedding向量。该向量是通过在DeepLabv3+（移除输出层）上再加了一个embedding层得到的。这个层的向量用来描述像素的类别向量。如果两个像素是同一类的，那么这两个像素对应的embedding向量之间的距离会很接近。如果两个像素不属于同一类，那么这两个像素对应的embedding向量的距离很远。

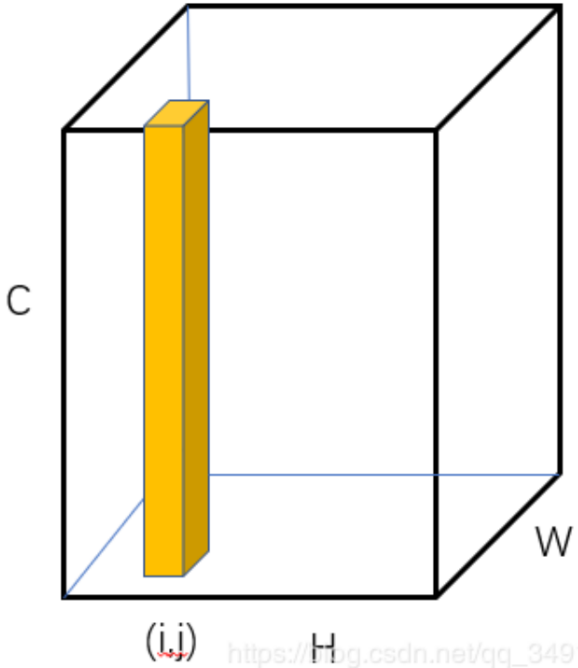

黄色块就是点(i,j)处的embedding向量。

接下来定义两个embedding向量间的距离。

$$d(p,q) = 1 - \frac{2}{1 + exp(||e_p - e_q||^2)}$$

e_p是对应于像素p的embedding向量，$d(p,q)$就是像素p到q在embedding空间的距离。距离越小，说明p和q是属于一类，反之亦然。
对于相同类别的像素，我们可以很轻松的求出d的值应该很接近0或者为0；对弈不同类别的像素，d接近1或者为1。

p可能来自第一帧的embedding 像素，也可能来自前一帧的embedding像素；而另一个q，则是来自当前帧的embedding像素。根据p的不同，计算两种distance map：Global distance map和 Local distance map，分别用到global matching和local matching。

Global matching

$$G_{t,o}(p) = \min_{q \in \mathcal{P}_{1,o}} d(p,q).$$

$$d(p,q) = 1 - \frac{2}{1 + exp(||e_p - e_q||^2)}$$

- P_t记作第t帧的所有像素集合。
- $P_{t,o} \subseteq P_t$记作，第t帧中属于类别O的像素集合。
- $p \in P_t$记作当前帧中的一个像素。
- $G_{t,o}(p)$记作p这个像素对应的global matching distance map的值

所以想要得到完整的global matching distance map，需要把当前帧所有的像素点的embedding向量，都和第一帧中属于同一类的embedding向量用之前定义的向量距离公式计算，然后取最小的距离值。这个过程其实相当费时间。论文中网络输入大小为465x465，即便经过deeplabv3+得到减少4倍的特征图，计算量仍然很大。

local matching

现在p属于前一帧的像素。计算公式仍然和全局匹配距离图的方法很相似。

$$\hat{G}_{t,o}(p) = \begin{cases} \min_{q \in \mathcal{P}_{t-1,o}} d(p,q) & \text{if } \mathcal{P}_{t-1,o} \neq \emptyset \\ 1 & \text{otherwise} \end{cases}$$

注意到前一帧可能没有目标的，所以有个otherwise选项。如果前一帧没有目标，那么得到的map都是1。
但是前一帧和当前帧中目标的移动一般是很小的，没有必要还去用当前embedding feature的一个向量对所有的第一帧的embedding向量计算距离。受到Flownet的启发，仅仅在一个k邻域的大小中计算距离。也就是用一个2*k+1的窗口约束q的位置。所以实际上使用的是下面的公式：

$$L_{t,o}(p) = \begin{cases} \min_{q \in \mathcal{P}^p_{t-1,o}} d(p,q) & \text{if } \mathcal{P}^p_{t-1,o} \neq \emptyset \\ 1 & \text{otherwise,} \end{cases}$$

$$\mathcal{P}^p_{t-1,o} := \mathcal{P}_{t-1,o} \cap N(p)$$

N§是在p的x和y方向上至多k个像素距离的像素集合。

Dynamic 分割头网络

网络输入有四样：两个distance map，前一帧的预测结果，当前帧的deeplabv3+的输出特征图（不含embedding layer）这个头网络结构简单，有四个深度分离卷积组成，产生一个一维的feature map用来预测类别，注意这个map仅仅为一个目标预测类别logits，所有实例目标都要经过这样的网络流程。所以每个实例都会得到一个一维的feature map，将它们stack一起，使用softmax，用一个交叉熵和label训练。

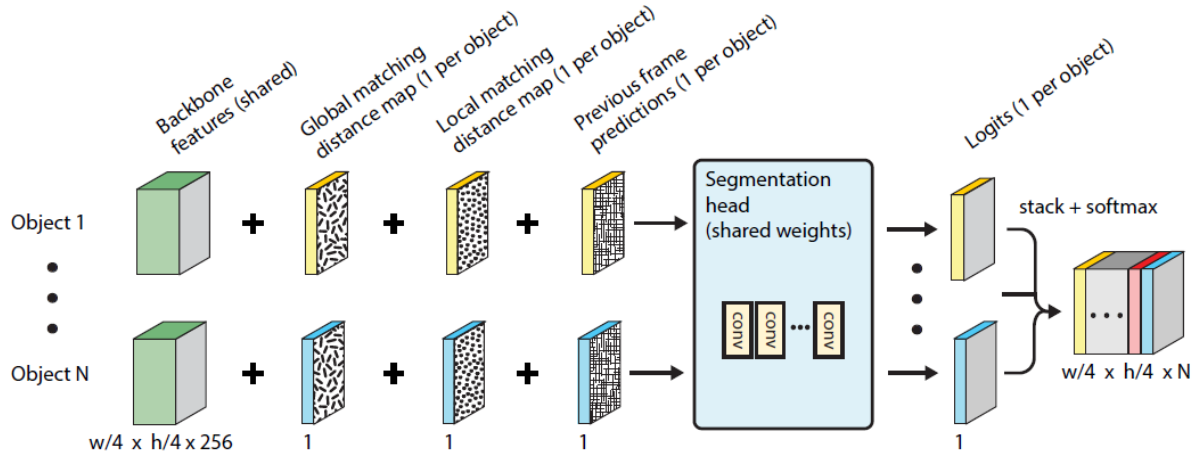

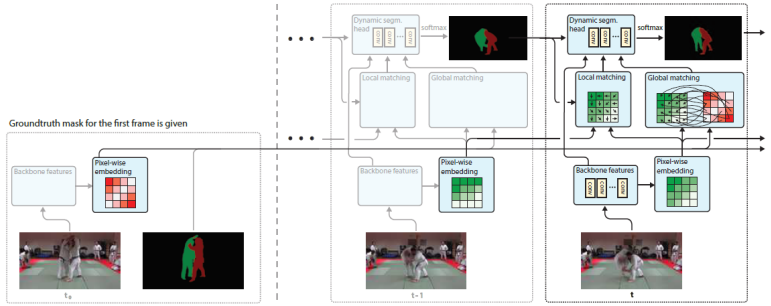

Figure 1. Overview of the proposed FEELVOS method. In order to segment the image of the current frame, backbone features and pixel-wise embedding vectors are extracted for it. Afterwards the embedding vectors are globally matched to the first frame and locally matched to the previous frame to produce a global and a local distance map. These distance maps are combined with the backbone features and the predictions of the previous frame and then fed to a dynamic segmentation head which produces the final segmentation. For details about handling of multiple objects see Fig. 3.

实验结果

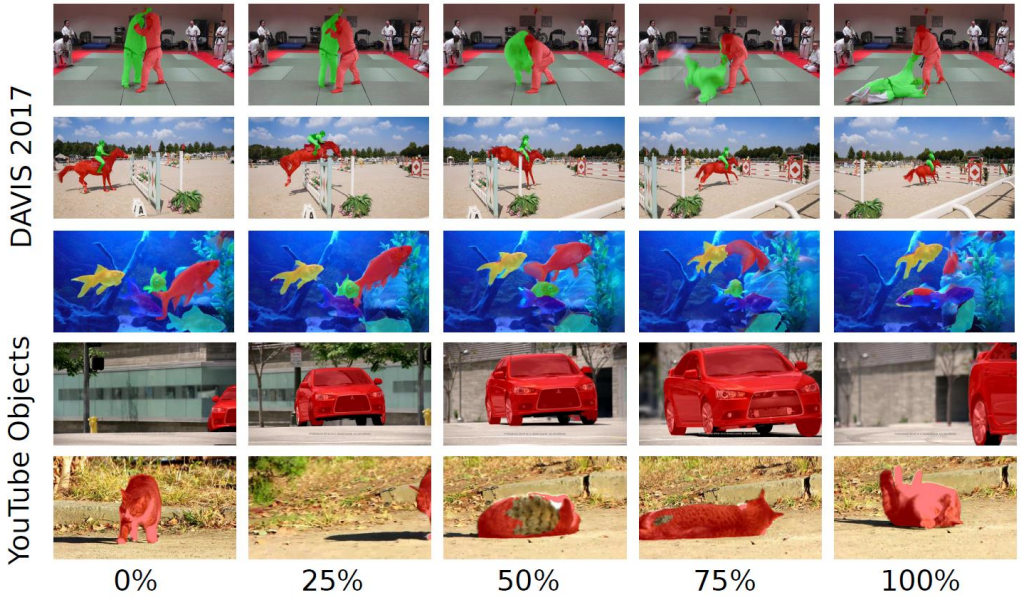

Figure 5. Qualitative results on the DAVIS 2017 validation set and on YouTube-Objects. In the third row the many similar looking fishes cause FEELVOS to lose track of some of them. In the last row, FEELVOS fails to segment some of the back of the cat.

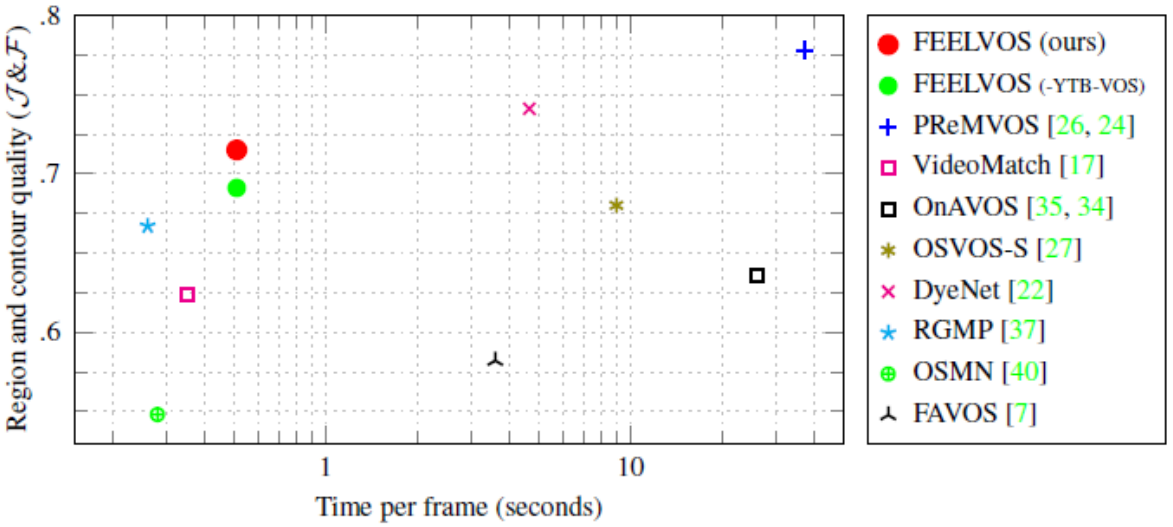

- 第5行中猫的背部没有标记出来，是因为第一帧猫的形态没有背部。但网络能从分割错误中恢复过来。这一点maskTrack就做不到。原因就是global matching使得当前帧存在和第一帧的联系，而不仅仅和相邻帧。