大论文工作

毛宽诚

2020/03/19

老师提的几个问题：

- 1，综述没有把我自己写的综述加上
- 2，章节标题不宜用英文缩写，尽量用中文
- 3，对比试验
- 4，NMS融合的尺度问题

综述

随着卷积神经网络在可见光行人检测领域中的成功应用，如何使用神经网络方法探讨可见光和红外图像信息融合实现全天候的行人检测引起了研究人员的注意。Wagner[30]等首次将深度卷积网络应用于双光谱行人检测，将对红外和可见光图像进行像素层面叠加合并为 4 通道图像然后输入神经网络，达到远超 ACF+T+THOG 的检测效果，Xu[31]等人利用存在的红外和可见光双模态数据集，训练了一个跨模态迁移网络，实现在仅有可见光图像输入的情况下模拟出红外的特征，达到了模拟出红外输入的效果。2016 年，Liu[32]采用双路深度卷积神经网络作为特征提取模块，实现了基于 Faster RCNN 算法的四种融合架构，分别为前端、中端、后端和决策层融合，实验结果中，中端融合模型表现最好。Konig[33]证明使用增强决策树比使用神经网络对候选区域的分类更加有效并基于 Faster RCNN 算法提出多种融合 RPN 结构用于提取候选区域，最后使用增强决策树对候选区域特征进行分类。Hang[34]提出一种跨模态交互注意力网络，首先分别使用可见光和红外两个通道输入提取特征，并分别引出分支计算通道注意力乘子，然后将乘子乘到融合特征图上。增强了两个模态的信息交互。Guan[35]对融合方式进行了多种探索，作者实验了特征图的级联、大小比较和求和三种融合方式，认为像素求和效果好于级联。虽然目前学术界对于可见光和红外图像的融合策略的研究已初见成效，但是准确性、实时性等方面依然有较大提升空间。2018 年以来，基于可见光/红外双谱融合行人检测算法从加权融合和多任务学习角度出发，设计出更加复杂的网络。文献[36][37][38]提出在两个模态检测网络后端将两个模态乘以不同权重进行加权融合，文献[36]使用一个专门的通道加权融合层进行融合，文献[37][38]使用单独一个分支判断该输入是白天还是黑夜并产生不同的权重系数，并将其称为光照感知网络，最后将该系数乘到两个模态的检测结果上进行重要程度分配。他们认为在不同时间段中，两个模态的重要程度不同。文献[35][39][40][41]为了使监督信息更加充分，都引入了分割损失进行辅助监督，分割损失的掩码标注使用图像形态学处理自动生成或者手动标注等手段，引入分割损失进行多任务学习后，使得双谱检测网络更加鲁棒。

第三章：基于ROI对齐的非极大值抑制融合双谱行人检测

(基于ROI Align的NMS融合算法)

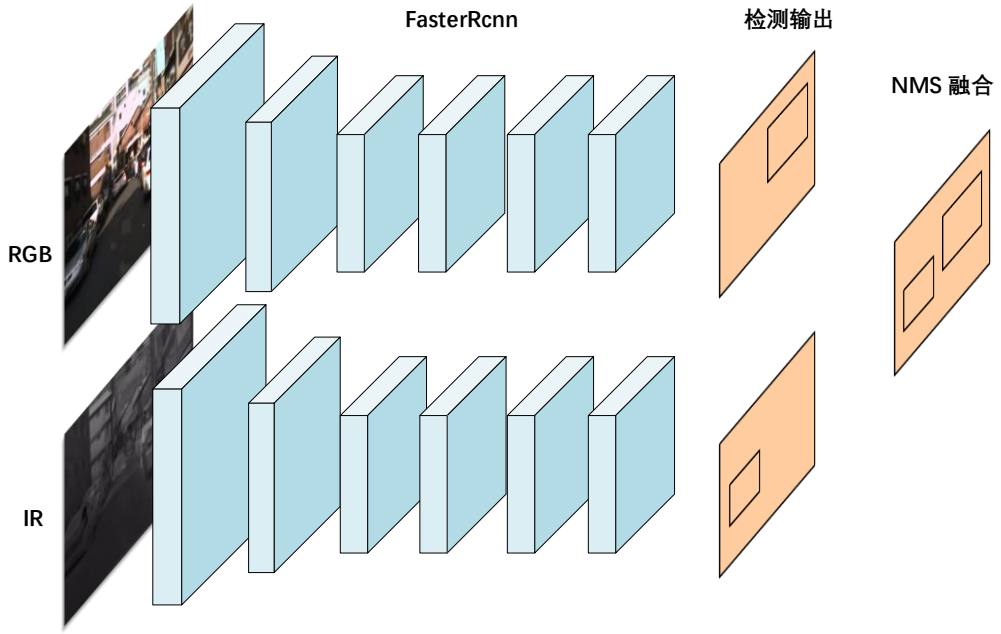

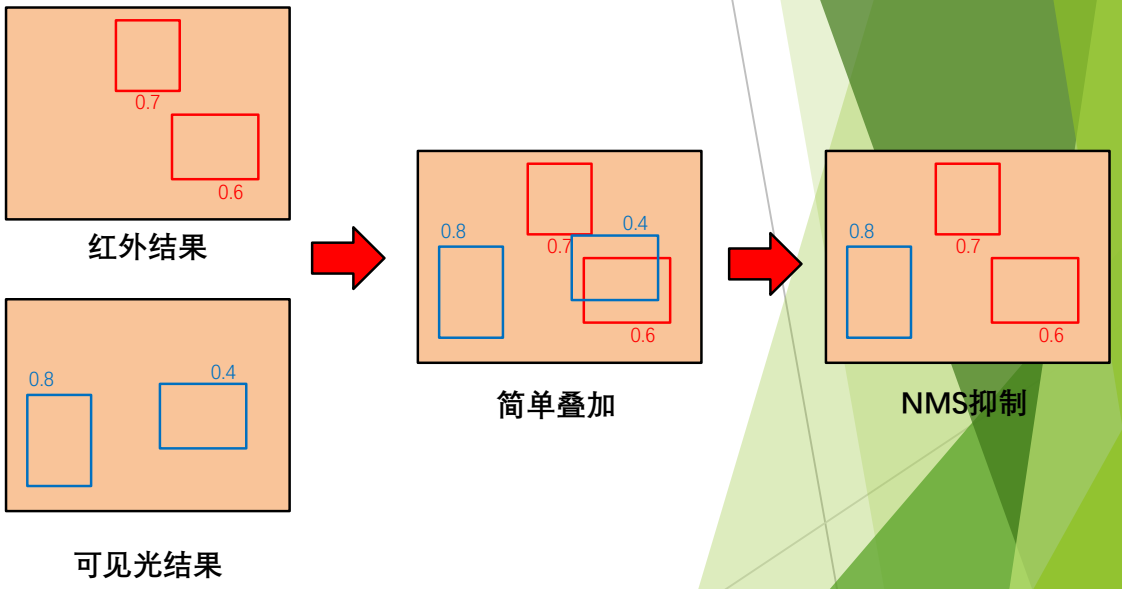

NMS融合的尺度问题

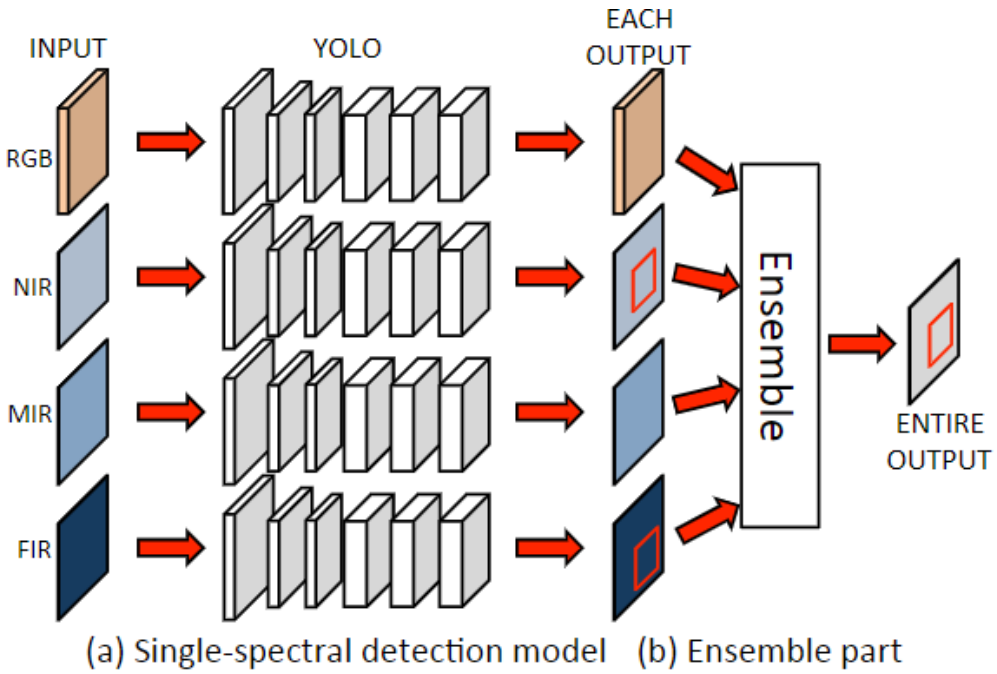

1. Takumi K, Watanabe K, Ha Q, et al. Multispectral object detection for autonomous vehicles[C]//Proceedings of the on Thematic Workshops of ACM Multimedia 2017. 2017: 35-43.

对比实验

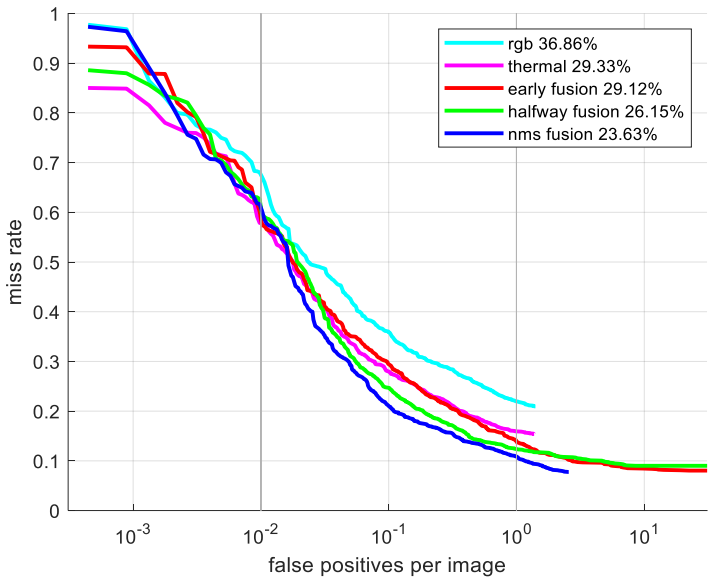

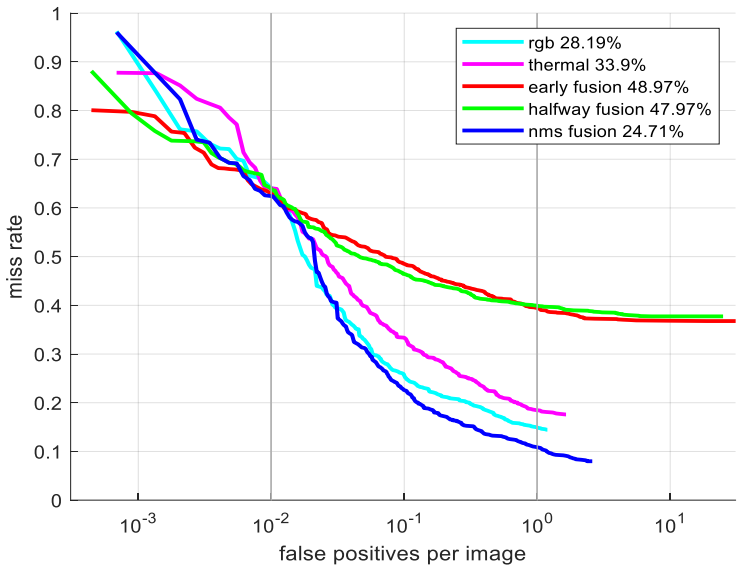

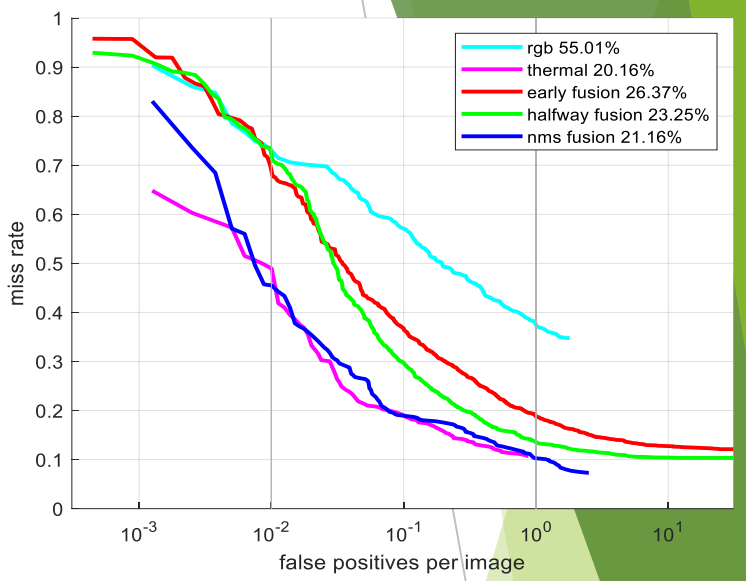

算法	全天(%)		白天(%)		夜晚(%)	
	LAMR	Recall	LAMR	Recall	LAMR	Recall
可见光(RGB)	36.86%	79.04%	28.19%	85.54%	55.01%	65.24%
热红外(Thermal)	29.33%	84.60%	33.90%	82.41%	**20.16%**	89.27%
前端融合(Early fusion)	29.12%	91.96%	48.97%	63.23%	26.37%	84.18%
中端融合(Halfway fusion)[32]	26.15%	84.67%	47.97%	62.27%	23.25%	87.74%
NMS 融合(NMS fusion)	**23.63%**	**92.23%**	**24.71%**	**92.01%**	21.16%	**92.70%**

	RGB	Thermal	Early Fusion	Half Fusion	NMS Fusion
速度(张/秒)	9.8	9.8	7.2	5.4	3.2

对数平均漏检率(Log Average Miss Rate，LAMR)和Recall

对于行人检测算法，Dollar[67]等人 2012 年提出使用 Miss Rate vs FPPI 曲线刻画算法的优劣，使用对数平均漏检率(Log Average Miss Rate，LAMR)作为最终评价标准，做法是在$10^{-2} \sim 10^{0}$范围的对数坐标内，在 Miss Rate vs FPPI 曲线上通过采样 9 个 FPPI 数值下的 Miss Rate 值求平均得到。Miss Rate 被称为漏检率，是分类器认为是正类但是实际是负类的部分占所有正类的比例，公式如下。

$$Miss\ Rate = \frac{FN}{TP + FN} \tag{3-2}$$

FPPI 全称为 False Positive Per Image，是平均每张图片的假负类个数。公式如下，其中 N_{img} 代表测试集的总图片数量

$$FPPI = \frac{FP}{N_{img}} \tag{3-3}$$

通过选取不同的阈值，可以对整个测试集计算出不同的[Miss Rate，FPPI]对，就可以画出 MissRate vs FPPI 的对数曲线，相比于通用目标检测常用的 Mean Average Precision(Map)指标，对数平均漏检率(LAMR)考虑了遮挡目标的检测效果，已经被公认为行人检测领域较好的评价指标[68]。同时，本文实验也使用 Recall 作为评价指标之一，Recall 是召回率，代表了算法检出正例的能力。本文统计所有置信度大于 0 的目标检测框，并计算 Recall。

$$Recall = \frac{TP}{TP + FN} \tag{3-4}$$

Table 1
Ablative Results on KAIST Test Set.

Methods\MR(%)\Subset	Daytime	Nighttime	All-day
CIAN(T)	33.36	22.05	30.04
CIAN(T+C)	31.63	23.33	29.14
CIAN(T+C+A)	**30.74**	**21.07**	**27.71**
CIAN(T+C+A⁻)	32.24	23.28	29.22

Ablative analysis of each proposed components. We evaluate the performance by log-average miss rate (MR).

- 第四章：基于多尺度ROI 对齐的RPN融合双谱行人检测
  (多尺度ROI Align的RPN融合)

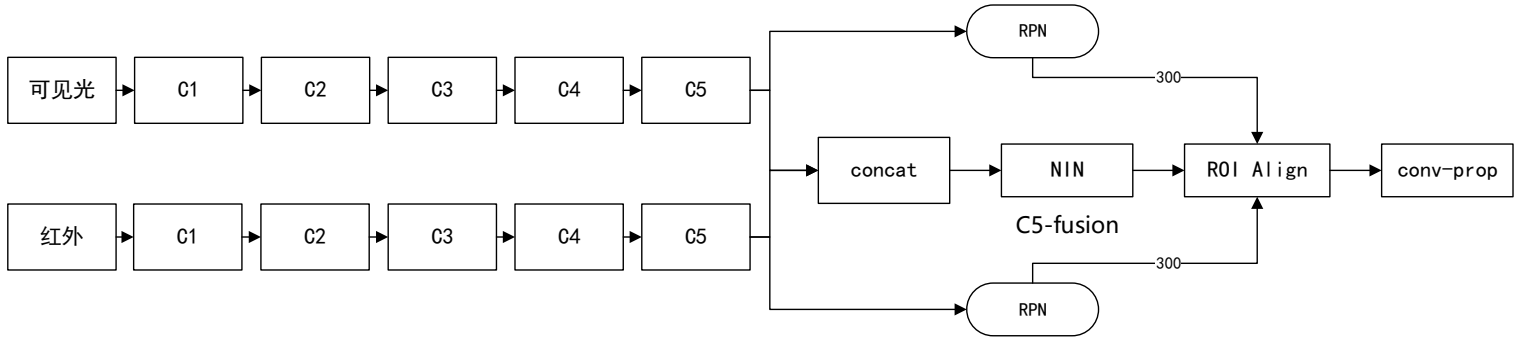

RPN融合网络

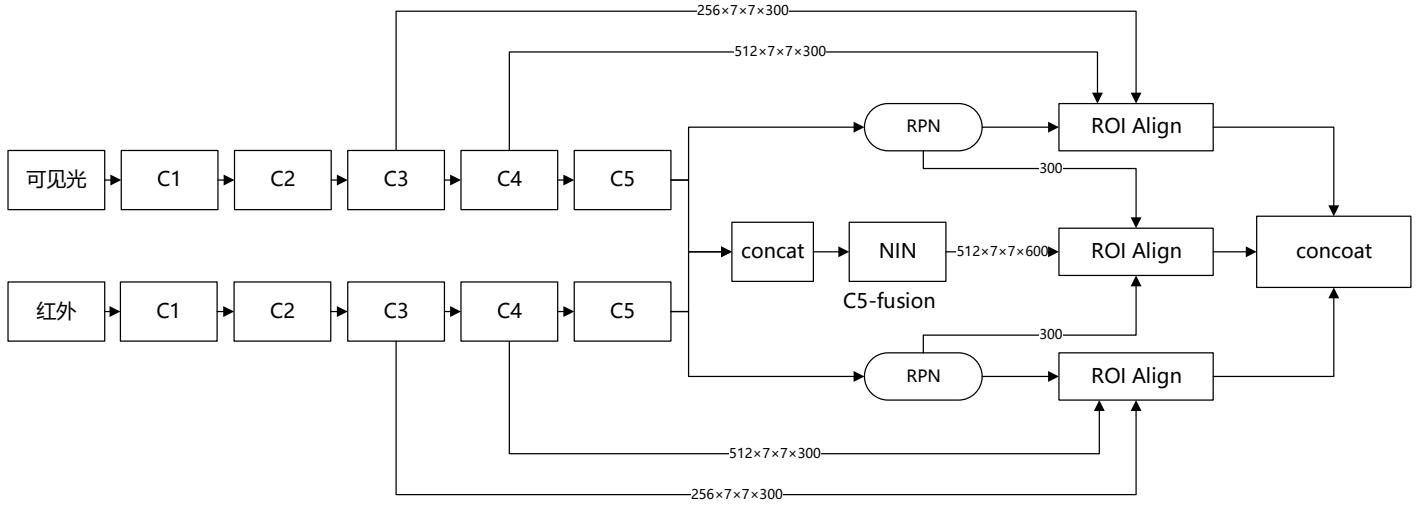

多尺度 ROI Align的RPN融合网络

实验

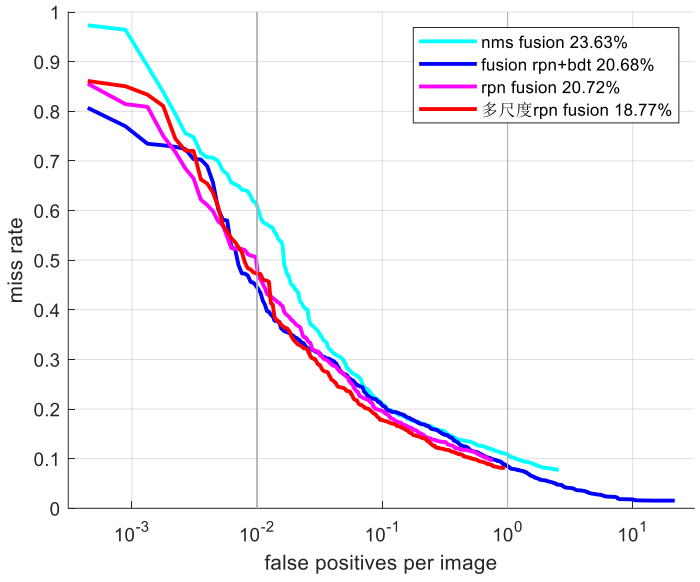

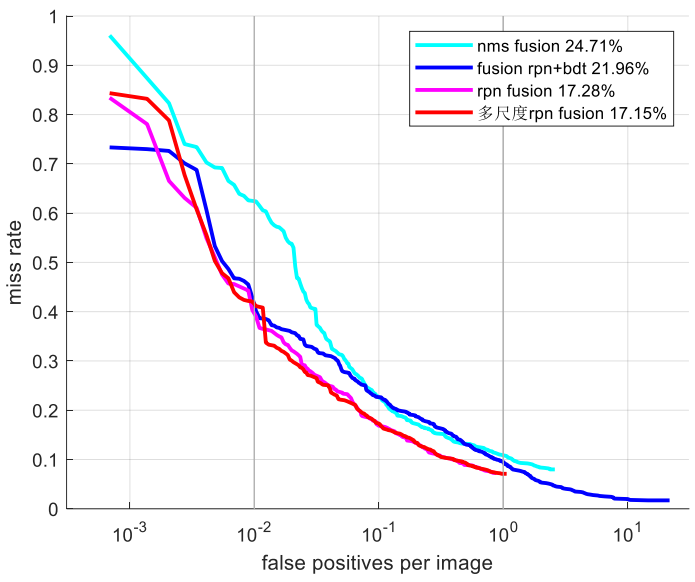

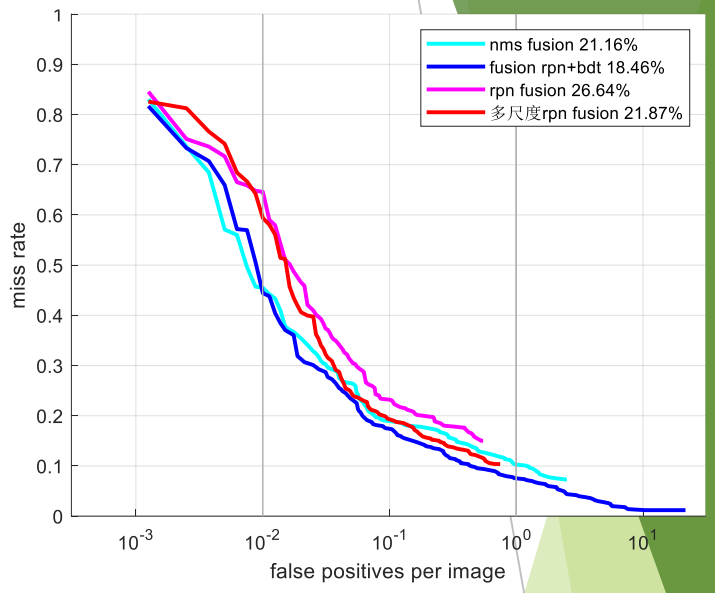

算法	全天		白天		夜晚	
	LAMR	Recall	LAMR	Recall	LAMR	Recall
NMS Fusion	23.63%	92.23%	24.71%	92.01%	21.16%	92.70%
Fusion RPN+BDT[33]	20.68%	**98.45%**	21.96%	98.29%	**18.46%**	**98.80%**
RPN Fusion	20.72%	90.24%	17.28%	92.72%	26.64%	84.98%
多尺度 RPN Fusion	**18.77%**	91.85%	**17.15%**	**92.90%**	21.87%	89.62%

Fusion RPN +增强决策数[33]

Konig[33]首先证明单独的 RPN 网络比完整的 Faster RCNN 在行人检测方面要更优秀。该方法首先使用中端融合[32]引出融合分支，接着对红外分支、可见光分支和融合分支这三个分支使用 ROI Pooling 并级联以增强特征信息，最后对融合的特征图使用增强决策树进行前背景分类，进一步提升分类效果。该方法首先肯定了 RPN 模块的重要性，缺点是依然使用的融合分支的 RPN 网络产生 ROI，未利用好两个模态的 RPN，增强决策树虽然分类精度更高，但是计算非常耗时，无法应用到实时环境中。

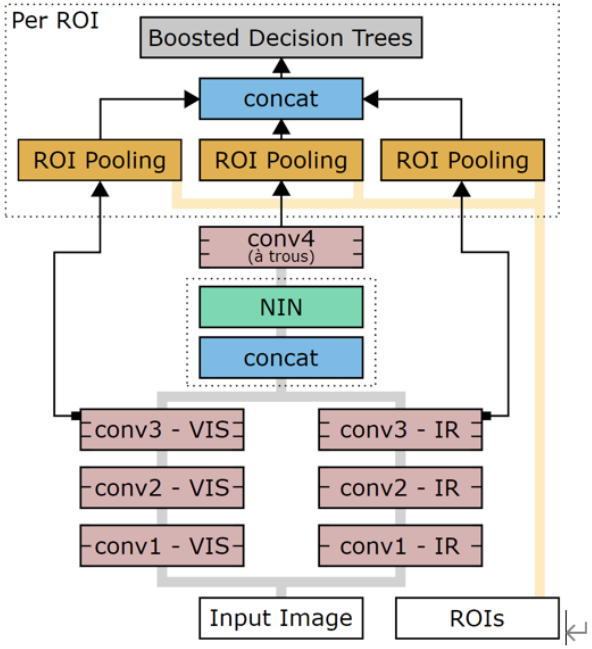

图 4.1　融合 RPN+增强决策数网络结构[33]

Fig. 4.1　The network of fusion RPN+BDT[33]

第五章：双谱行人检测推理速度优化及平台移植

- 1，TensorRT优化原理
- 2，软硬件平台
- 3，部署流程
- 4，实验及效果

论文工作

- 第五章：双谱行人检测推理速度优化及平台移植
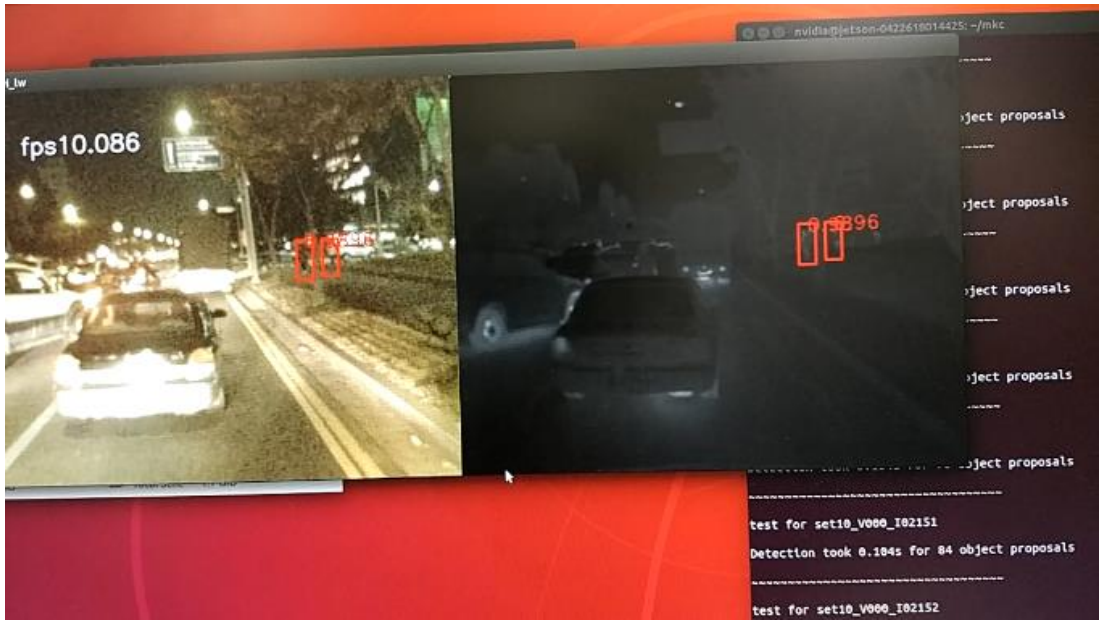
框架	FPS(张/秒)	速度(秒/张)	LAMR
Caffe	1.12	0.892	27.38%
TesonRT	9.523	0.105	27.85%