简介

- 降水临近预报是指利用**雷达回波图1、雨量计**等观测数据，结合数值天气预报(NWP)模型，对局部地区降水强度进行极短时间(如0-6小时)预报的问题。

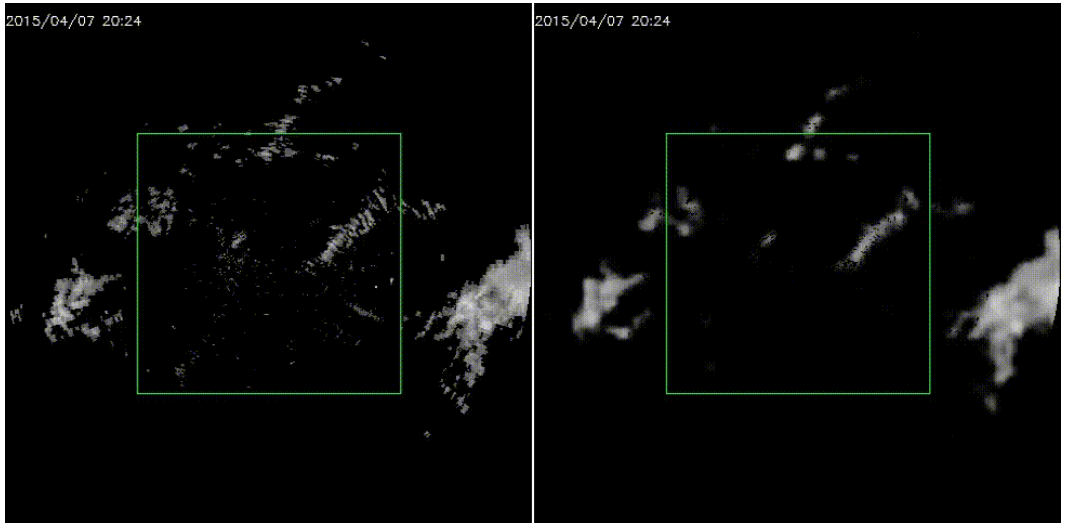

相同点：外形运动特征相似，雷达回波是（0~1）的数值（烟雾浓度）

不同点：降水临近预报　　时空序列预测问题　　已知0-6小时降水图，预测7-12时降水图

　　烟雾分割　　视频语义分割

模型结构

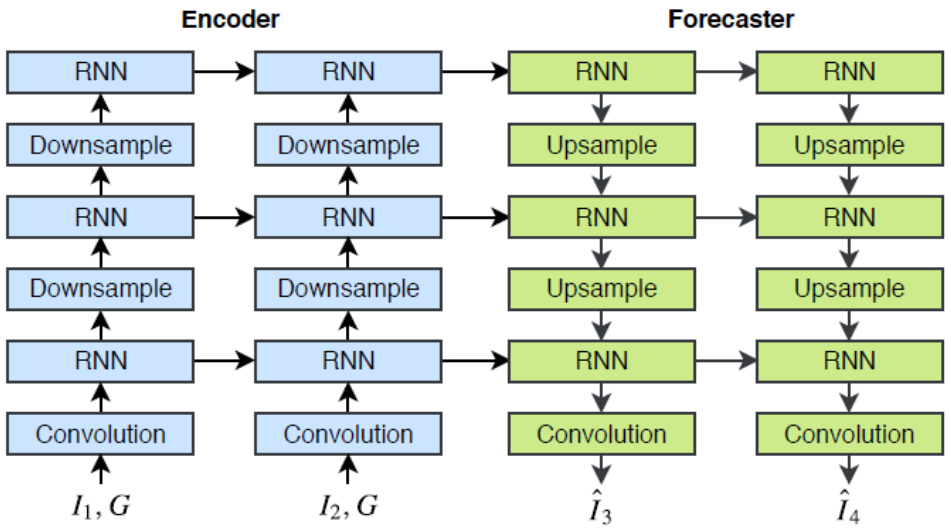

Figure 1: Example of the encoding-forecasting structure used in the paper. In the figure, we use three RNNs to predict two future frames $\hat{I}_3, \hat{I}_4$ given the two input frames I_1, I_2. The spatial coordinates G are concatenated to the input frame to ensure the network knows the observations are from different locations. The RNNs can be either ConvGRU or TrajGRU. Zeros are fed as input to the RNN if the input link is missing.

RNN：convgru

trajgru（本文提出）

The reason to reverse the order of the forecasting network is that the high-level states, which have captured the global spatiotemporal representation, could guide the update of the low-level states. Moreover, the low-level states could further influence the prediction.

而 TrajGRU 使用 GRU 结构，区别是首先使用了一个 $32@5k2p1s$ 的卷积层对隐藏态进行卷积提取光流，然后使用 $2L@1k1s$ 的卷积层对光流进行卷积，建立一个动态的对应关系。

按照作者的说法，普通卷积网络的对应关系不变，对于 local-invariant 的操作比较合适，而 local-variant 的操作比如旋转普通卷积是不够的。相比普通卷积固定的领域集，TrajGRU 可以有 L 个变化的领域集，并且参数要少于原来的普通卷积。我的想法是云层的运动与消散是动态的，一团云在某一帧的位置对应到下一帧的位置不一样，所以需要建立一个动态的链接。

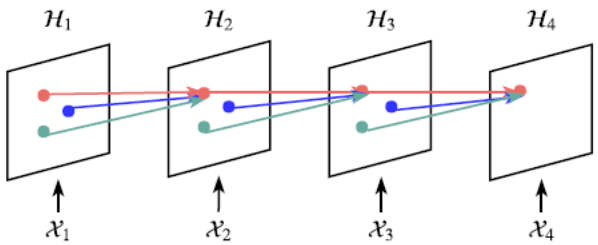

(a) For convolutional RNN, the recurrent connections are fixed over time.

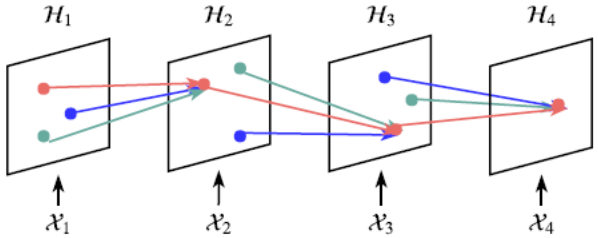

(b) For trajectory RNN, the recurrent connections are dynamically determined.

Figure 2: Comparison of the connection structures of convolutional RNN and trajectory RNN. Links with the same color share the same transition weights. (Best viewed in color)

GRU

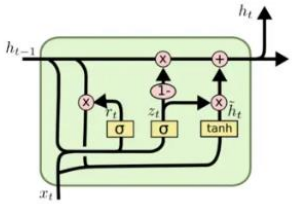

$$z_t = \sigma\left(W_z \cdot [h_{t-1}, x_t]\right)$$
$$r_t = \sigma\left(W_r \cdot [h_{t-1}, x_t]\right)$$
$$\tilde{h}_t = \tanh\left(W \cdot [r_t * h_{t-1}, x_t]\right)$$
$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$$

reset gate r_t 、update gate z_t 、候选隐藏层 $\tilde{h}_t$ （与 LSTM 的 $\tilde{c}_t$ 类似，可以看成是当前时刻的新信息，其中 r_t 用来控制需要保留多少之前的记忆）

为了克服RNN 无法很好处理远距离依赖而提出了 LSTM，而 GRU 是LSTM 的一个变体，GRU 保持了 LSTM 的效果同时又使结构更加简单。

GRU 只剩下两个门，即**更新门**和**重置门**。更新门用于控制前一时刻的状态信息被代入到当前状态的程，更新门的值越大说明前一时刻的状态信息带入越多。重置门用于控制忽略前一时刻的状态信息的程度，重置门的值越小说明忽略得越多。

比较

TrajGRU 的公式如下，首先使用一个子网络提取光流 $\mathcal{U}_t, \mathcal{V}_t$，然后使用 `wrap` 函数变换，有 L 个链接。

$$\mathcal{U}_t, \mathcal{V}_t = \gamma\left(\mathcal{X}_t, \mathcal{H}_{t-1}\right)$$
$$\mathcal{Z}_t = \sigma\left(\mathcal{W}_{xz} * \mathcal{X}_t + \sum_{l=1}^{L} \mathcal{W}_{hz}^{l} * warp\left(\mathcal{H}_{t-1}, \mathcal{U}_{t,l}, \mathcal{V}_{t,l}\right)\right)$$
$$\mathcal{R}_t = \sigma\left(\mathcal{W}_{xr} * \mathcal{X}_t + \sum_{l=1}^{L} \mathcal{W}_{hr}^{l} * warp\left(\mathcal{H}_{t-1}, \mathcal{U}_{t,l}, \mathcal{V}_{t,l}\right)\right)$$
$$\mathcal{H}_t' = f\left(\mathcal{W}_{xh} * \mathcal{X}_t + \mathcal{R}_t \circ \left(\sum_{l=1}^{L} \mathcal{W}_{hh}^{l} * warp\left(\mathcal{H}_{t-1}, \mathcal{U}_{t,l}, \mathcal{V}_{t,l}\right)\right)\right)$$
$$\mathcal{H}_t = (1 - \mathcal{Z}_t) \circ \mathcal{H}_t' + \mathcal{Z}_t \circ \mathcal{H}_{t-1}$$

`wrap` 函数的 mxnet 可以参考 traj_rnn.py#L14，pytorch 没有该函数，可以参考我的实现 trajGRU.py#L9。

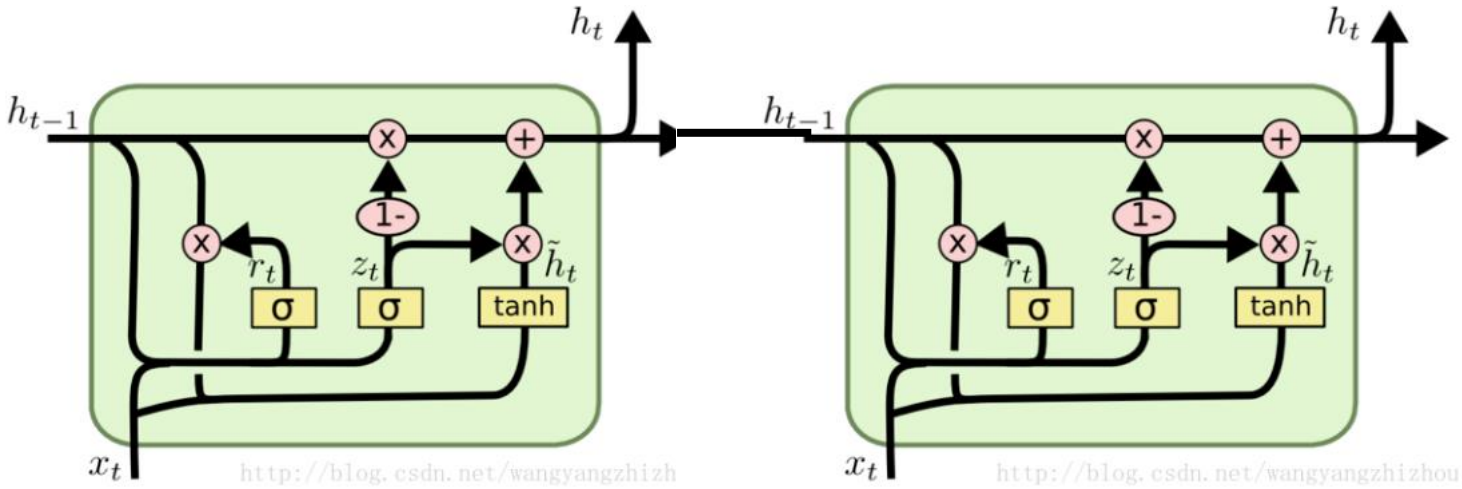

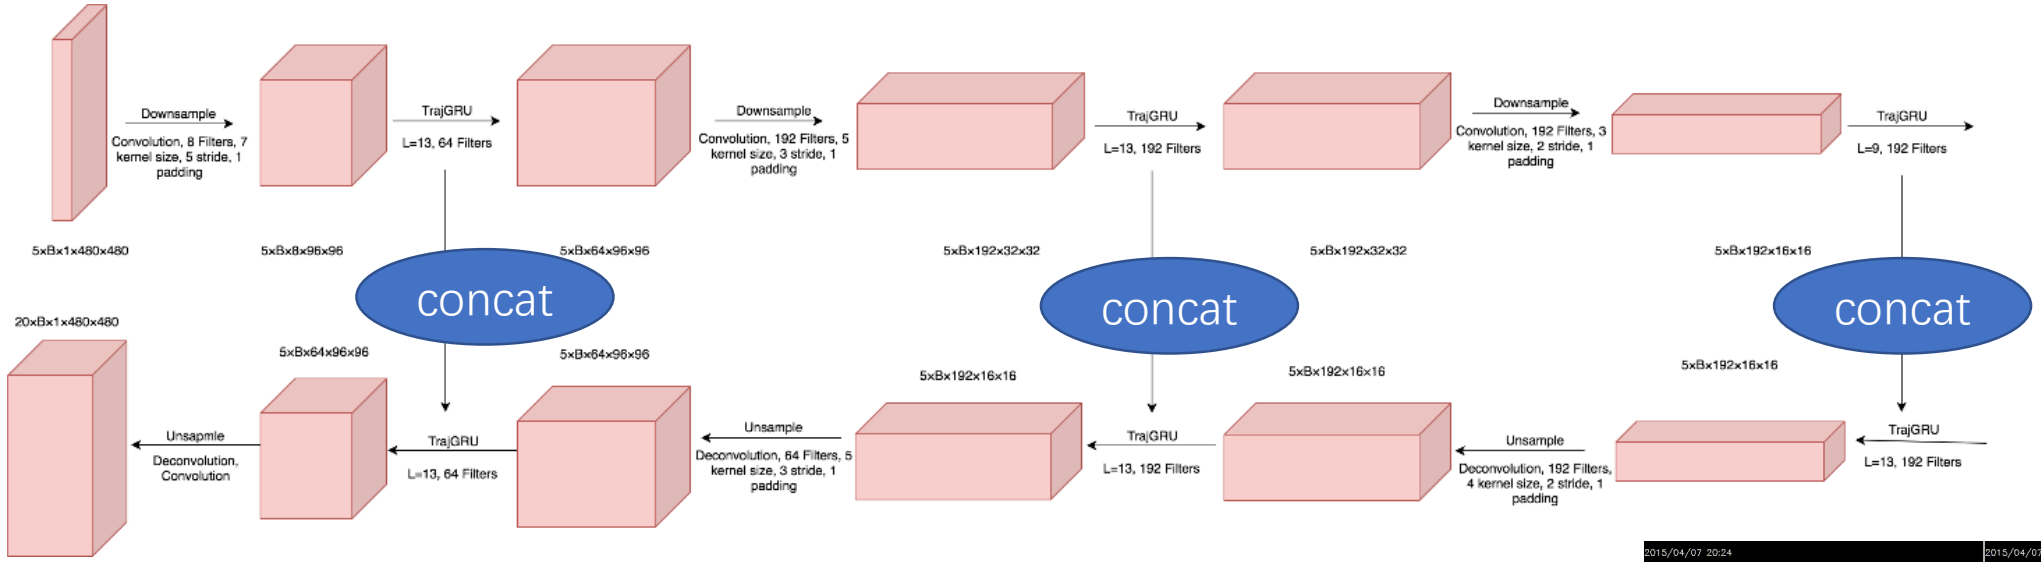

通过实验发现，TrajGRU 取得了比 ConvGRU、Conv3d、光流法等方法更好的结果；所有深度学习方法都取得了比其他方法更好地结构；文中的 Baseline 是直接使用最后一帧的作为未来所有帧的预测结果。

虽然结果可能不错，在实际预测时还是发现了越往后的输出越暗，即越往后误差越大，

问题：对于降水预报问题，预测效果好时因为：
1.具有对于某一时刻，前一时刻的信息总是相对准确
2.光流网络作为子网络，预测光流的流向作为预测的依据，对于需要预测的目标云具有追踪作用。
对于烟雾检测问题：
1.每一时刻的信息都不准确但是相互之间存在关联
2.光流的预测是否有效？

loss
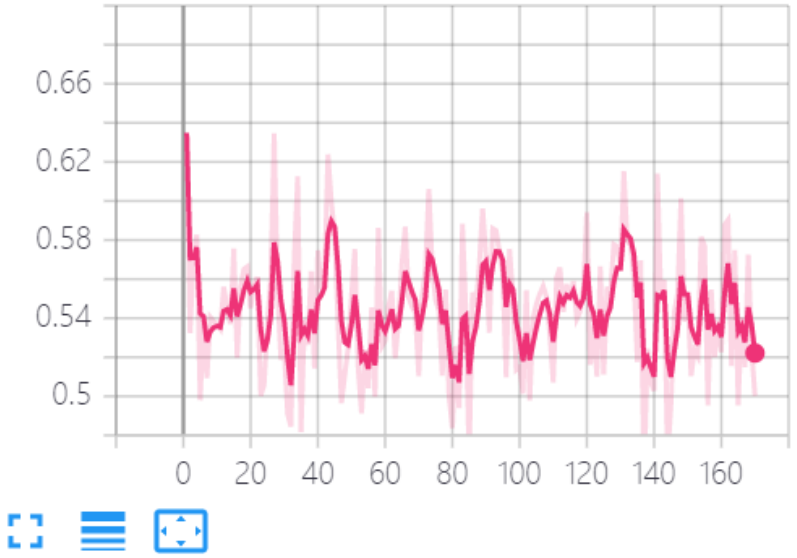
loss