工作汇报

张鹤

2020.4.9

C-均值算法——k-means

算法思路：

1.读取wine数据集

2.取第0列为y训练集，第1列到第177列为x训练集

3.对x训练集预处理（归一化）

4.初始化类心方式：

a. 随机

b. k次，选取178/k个数据，取平均值（数据量大的时候速度更快，数据接近）

输入：train_x， 聚类数k，初始化类心方式

a. 循环178次，求每个点到k个类心的欧式距离，返回距离最小的变量值，用来划给最近的类

b. 循环k次，把属于同一类的数据集求平均值，赋值给新的类心

c. 判断新的类心与原来类心的欧氏距离，若差值大于阈值（我设置的是0），循环abc操作

d. 否则，退出循环，计算b完成次数（迭代次数），计算最后一次划分属于同一类心的数据与该类心的距离平方和（簇内平方和 SSE）

输出：类心位置，分类，迭代次数，SSE

出现问题

得到的分类是随机的，不一定是（1 2 3 类顺序排）

[1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1
1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 3 2 2 3 3 3 3 3 3 2 3 2 3 3 1
3 3 3 3 3 3 3 3 3 2 3 3 3 3 3 3 3 3 3 3 3 1 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3
3 3 3 3 3 3 3 2 3 3 3 3 3 3 3 3 3 3 3 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2
2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2]

原始数据集：59 个 1　　，71 个 2　　，48 个 3

解决方法：众数

把算法得到的数据集，按照众数大小分配1 2 3类，同理，把原始标签按照众数分配 1 2 3类

设计实验

1.对比有无预处理（归一化）对实验数据的影响

2.对比不同初始类心选择对实验数据的影响

3.分不同类，对簇内平方和的影响

实验分析

	预处理+随机	无预处理+随机
SSE	13.47084207	474018.1664
accuracy	0.94662921	0.70224719
time	0.03377372	0.020142913
迭代次数	6	4.5

四组数据取平均
可以对比得到，预处理化情况下正确率更高

	随机选择	平均
SSE	13.47084207	13.88465508
accuracy	0.94662921	0.948033705
time	0.03377372	0.024766862
迭代次数	6	6

四组数据取平均
数据量大的情况下，平均所用时间更短
在wine数据集下，类心距离比较近反而效果会更好一点？

2	3	4	6	8	10	12	14	16	18	20
28.2561	13.47084207	11.373433	8.861157	4.565671	3.2903	2.744772168	2.183711881	1.450859898	0.802790981	0.951403676
0.02927	0.03377372	0.0287692	0.049034	0.034522	0.036	0.040027261	0.033647239	0.03952682	0.037150204	0.041027725

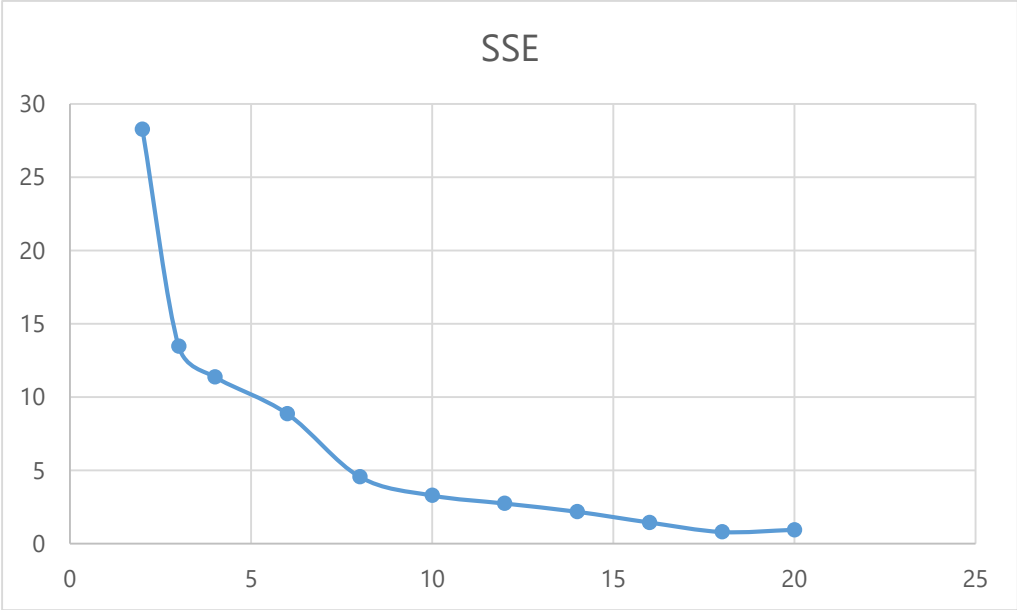

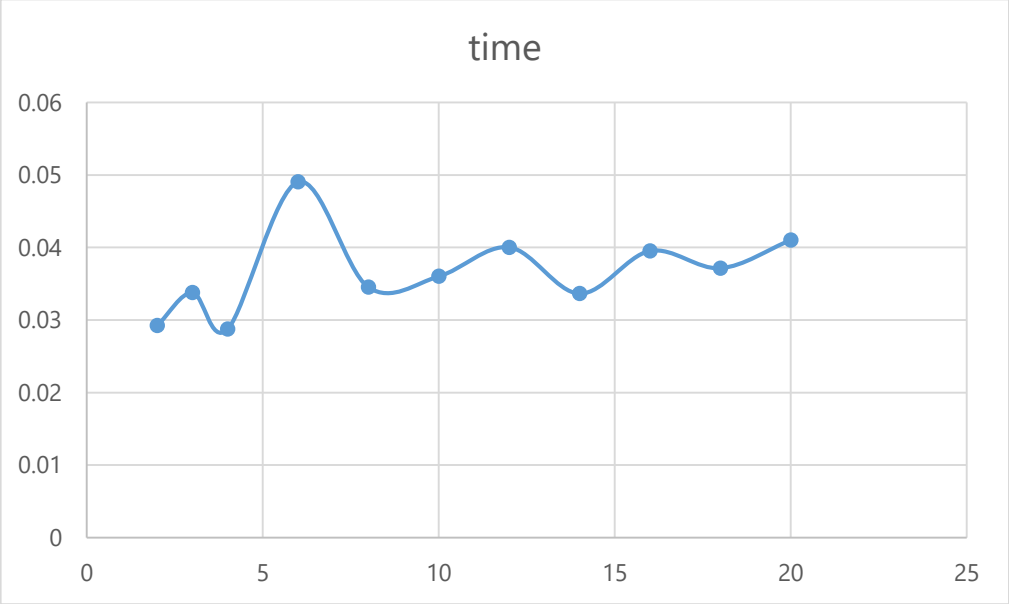

Sklearn_KMeans

最终收敛	[[0.70565142 0.24842869 0.58490401 0.3444313 0.41072701 0.64211419 0.55467939 0.30034024 0.47727155 0.35534046 0.47780888 0.69038612 0.59389397]
	[0.54668616 0.48440931 0.56159636 0.53865979 0.31521739 0.2467433 0.10474293 0.61425577 0.22543521 0.48878144 0.18888889 0.15852666 0.24911502]
	[0.31336675 0.23561704 0.47304983 0.50024546 0.24551415 0.44805692 0.38008171 0.41868823 0.39717591 0.14778699 0.47218996 0.58422001 0.15637525]]
silhouette	0.301346327

[[0.544689 0.47844053 0.56013612 0.53833177 0.31146245 0.24476489 0.10713464 0.61852487 0.22827646 0.4826404 0.19254989 0.16090576 0.24739982]
[0.31566416 0.24330259 0.47330447 0.49762723 0.2494824 0.45495348 0.38399973 0.41090147 0.3973762 0.14956119 0.47038328 0.58968545 0.15846976]
[0.7077193 0.24189723 0.58636364 0.34424399 0.4115942 0.64327586 0.55587201 0.29937107 0.47865405 0.35688282 0.48116531 0.69133089 0.59901331]]

1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 3 2 2 3 3 3 3 3 3 2 3 2 3 3 1
3 3 3 3 3 3 3 3 3 2 3 3 3 3 3 3 3 3 3 3 3 1 3 3 3 3 3 3 3 3 3 3 3 3 3 3
3 3 3 3 3 3 3 2 3 3 3 3 3 3 3 3 3 3 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2
2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2]

59个1	71-7=64	48	accuracy	0.960674157

预处理+随机
13.47084207
0.94662921
0.03377372
6

Thank You!