文献汇报

高铭阳

2019.12.26

Mobile Video Object Detection with Temporally-Aware Feature Maps

Mason Liu
Georgia Tech*
masonliuw@gatech.edu

Menglong Zhu
Google
menglong@google.com

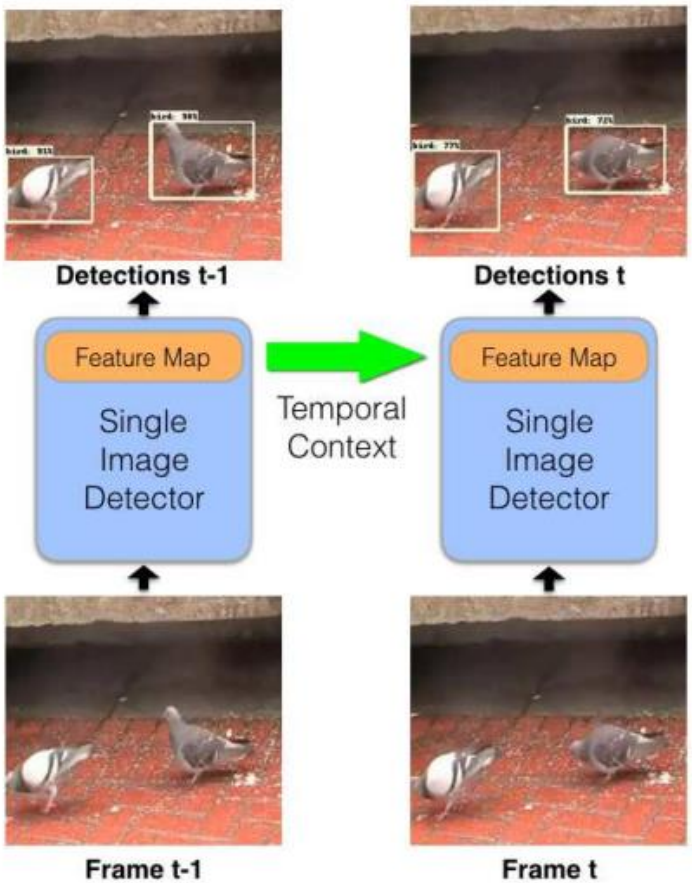

动机

近几年图像目标检测算法在深度学习的助力下取得了令人瞩目的成就，但是在将其实际运用在视频检测当中会遇到很多图像目标检测算法很难解决的困难，例如检测不稳定，计算量等。并且会遗失视频中重要的时序信息（帧间的相关性），这些信息无疑会帮助提升视频目标检测的精度和速度。本文作者将conv-LSTM进一步改进并嵌入到现有的目标检测算法当中，旨在合理利用时序信息（将早期帧的检测信息用于当前检测）优化检测，同时可以实时检测。

贡献

本文的贡献如下：

1、引入了统一的架构，用于在需要最少计算资源的视频中执行在线对象检测。

2、我们提出卷积体系中循环层的新角色作为特征映射的时间细化。

3、通过将卷积LSTM修改为高效，我们证明了在以效率为中心的网络中使用循环层的可行性。

方法

对于视频目标检测任务描述如下

对于给定的视频序列 $\mathcal{V}=\{I_0, I_1, \ldots I_n\}$，我们想得到结果序列为$\{D_0, D_1, \ldots D_n\}$。

单帧图像目标检测方法：$\mathcal{G}\left(I_t\right)=D_t$

加入时序信息后可以定义为：$\mathcal{F}\left(I_t, s_{t-1}\right)=\left(D_t, s_t\right)$，其中$s_k=\left\{s_k^0, s_k^1, \ldots s_k^{m-1}\right\}$，表示$k$帧之前特征映射的集合。

现在通过带有m层LSTM的目标检测器去拟合这个函数。

将LSTM集成到SSD中

在这里认为LSTM的状态单元s_t带有时间上下文信息，LSTM可以将此状态单元和输入特征结合，将时间信息有选择的添加到输入特征中去，同时更新状态单元。作者认为可以将这样的LSTM层加到原来目标检测器的任意一层之后以细化下一层的输入特征。具体而言，我们将上面所定义的单帧图像目标检测函数$\mathcal{G}\left(I_t\right)=D_t$分裂为$m+1$个子网络，所以目标检测器函数就变成了这个样子$G\left(I_t\right)=\left(g_m \circ \cdots \circ g_1 \circ g_0\right)\left(I_t\right)$，之后我们将$m$层LSTM $\mathcal{L}_0, \mathcal{L}_1, \ldots \mathcal{L}_{m-1}$ 逐层添加到其中：

$$
\begin{aligned}
\left(M_+^0, s_t^0\right) &= \mathcal{L}_0\left(g_0\left(I_t\right), s_{t-1}^0\right) \\
\left(M_+^1, s_t^1\right) &= \mathcal{L}_1\left(g_1\left(M_+^0\right), s_{t-1}^1\right) \\
&\vdots \\
\left(M_+^{m-1}, s_t^{m-1}\right) &= \mathcal{L}_{m-1}\left(g_{m-1}\left(M_+^{m-2}\right), s_{t-1}^{m-1}\right) \\
D_t &= g_m\left(M_+^{m-1}\right)
\end{aligned}
$$

M为特征映射。

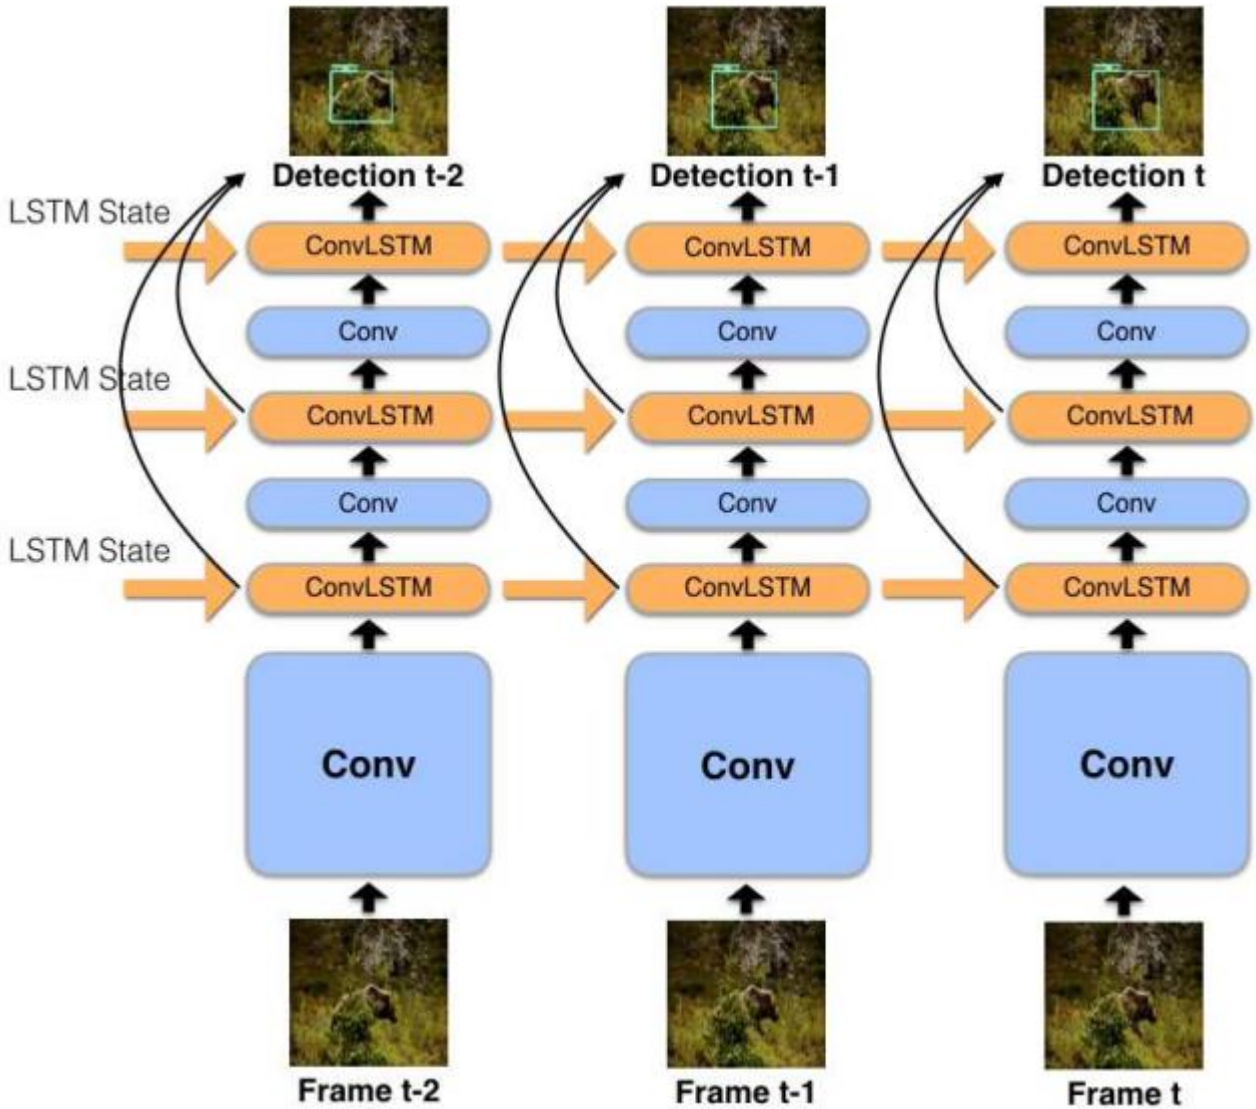
Detection t-2
Detection t-1
Detection t
LSTM State
LSTM State
LSTM State
ConvLSTM
Conv
ConvLSTM
Conv
ConvLSTM
Conv
Frame t-2
Frame t-1
Frame t

LSTM放置方法

1.在Conv13层之后放置一个LSTM。
2.在Conv13层之后堆叠多个LSTM。
3.在每个特征图后放置一个LSTM

Placed After	mAP
No LSTM (baseline)	50.3
Conv3	49.1
Conv13	**53.5**
Feature Map 1	51.0
Feature Map 2	50.5
Feature Map 3	50.8
Feature Map 4	51.0
Outputs	51.2

Place Bottleneck-LSTMs After					mAP		Params (M)		MAC (B)	
Conv13	FM1	FM 2	FM 3	FM 4	$\alpha = 0.5$	$\alpha = 1.0$	$\alpha = 0.5$	$\alpha = 1.0$	$\alpha = 0.5$	$\alpha = 1.0$
✓					42.8	53.5	**0.81**	**3.01**	**0.19**	**1.12**
✓✓					42.9	53.3	0.91	3.41	0.20	1.16
✓	✓				43.3	53.7	0.82	3.07	0.19	1.13
✓	✓	✓			43.5	54.0	0.82	3.11	0.19	1.13
✓	✓	✓	✓		**43.8**	**54.4**	0.85	3.21	0.19	1.13
✓	✓	✓	✓	✓	**43.8**	**54.4**	0.86	3.24	0.19	1.13

Table 4: Performance of our architecture with multiple Bottleneck-LSTMs. Layer names match Table 1, where FM stands for Feature Map. ✓denotes a single LSTM placed after the specified layer, while ✓✓denotes two LSTMs placed.

改进宽度乘子

First, we address the dimensionality of the LSTM. We can obtain finer control over the network architecture by extending the channel width multiplier α defined in [17]. The original width multiplier is a hyperparameter used to scale the channel dimension of each layer. Instead of applying this multiplier uniformly to all layers, we introduce three new parameters $\alpha_{base}, \alpha_{ssd}, \alpha_{lstm}$, which control the channel dimensions of different parts of the network.

Any given layer in the base Mobilenet network with N output channels is modified to have $N\alpha_{base}$ output channels, while α_{ssd} applies to all SSD feature maps and α_{lstm} applies to LSTM layers. For our network, we set $\alpha_{base} = \alpha$, $\alpha_{ssd} = 0.5\alpha$, and $\alpha_{lstm} = 0.25\alpha$. The output of each LSTM is one-fourth the size of the input, which drastically cuts down on the computation required.

改进LSTM

- 作者首先用深度分离卷积替换所有的卷积运算。
- 为了保持LSTM前后特征的分布不变，这里的激活函数ϕ使用的是ReLU。
- 作者还用Bottleneck Features进一步缩减了运算量，思路是这样的原来的LSTM每个门都需要将输入维度$M+N$转换为输出维度N，增加了计算量。作者先引入了一个Bottleneck layer $b_t = \phi\left({}^{(M+N)}W_b^N \star [x_t, h_{t-1}]\right)$ 先完成这个变换，将其输出作为其他运算的输入，如下图。

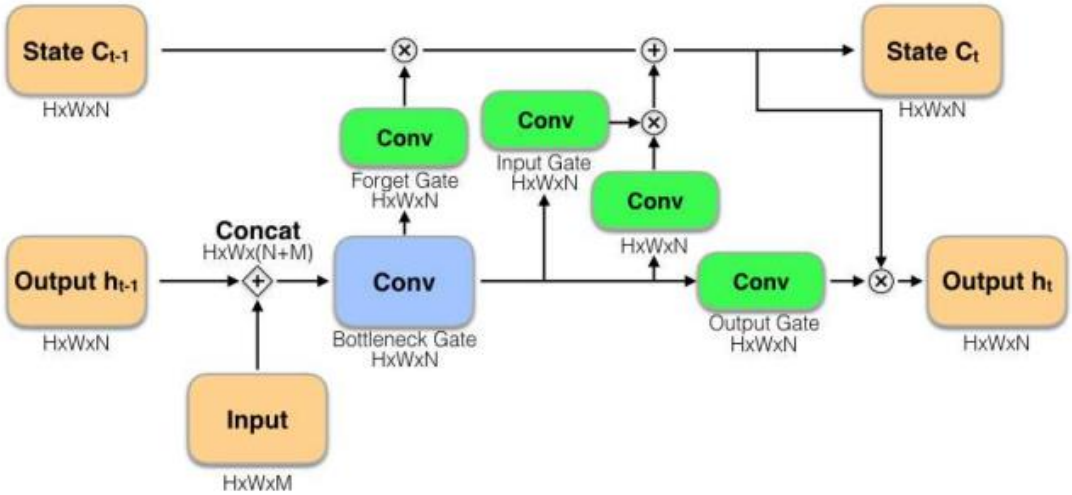

$$
\begin{aligned}
f_t &= \sigma({}^{(M+N)}W_f^N \star [x_t, h_{t-1}]) \\
i_t &= \sigma({}^{(M+N)}W_i^N \star [x_t, h_{t-1}]) \\
o_t &= \sigma({}^{(M+N)}W_o^N \star [x_t, h_{t-1}]) \\
c_t &= f_t \circ c_{t-1} + i_t \circ \phi({}^{(M+N)}W_c^N \star [x_t, h_{t-1}]) \\
h_t &= o_t \circ \phi(c_t).
\end{aligned}
$$

对比

α	Type	mAP	Params (M)	MAC (M)
0.5	Averaging	37.6	–	–
	LSTM	43.3	2.11	135
	GRU	**44.5**	1.59	102
	Bottleneck-LSTM	42.8	**0.15**	**5.6**
1.0	Averaging	50.7	–	–
	LSTM	53.5	8.41	840
	GRU	**54.0**	6.33	632
	Bottleneck-LSTM	53.5	**0.60**	**34**

实验

Model	mAP	Params (M)	MAC (B)
Resnet-101 Faster-RCNN	62.5	63.2	143.37
Inception-SSD	56.3	13.7	3.79
Mobilenet-SSD ($\alpha = 1$)	50.3	4.20	1.20
Ours ($\alpha = 1$)	**54.4**	**3.24**	**1.13**
Mobilenet-SSD ($\alpha = 0.5$)	40.0	1.17	0.20
Ours ($\alpha = 0.5$)	**43.8**	**0.86**	**0.19**